



Universidad de San Carlos de Guatemala
Facultad de Ingeniería
Escuela de Estudios de Postgrado

**MODELO DE VISIÓN Y MEMORIA ARTIFICIAL CAPAZ DE GENERAR UN
DIAGNÓSTICO MÉDICO POR PACIENTE CON DIFERENTE NÚMERO DE
IMÁGENES TOMOGRÁFICAS EN LA CIUDAD DE GUATEMALA,
GUATEMALA**

Lic. Diana María Letona Lee
Ing. Erick Alexander Ramírez Tebalán
Ing. Marvin Francisco Castillo Barrera

Med. Mildred Cristina Aspuac Sánchez
Ing. Luis Fernando Juárez Pacheco
Ing. Luis Fernando Leal Hernández

**Especialización en
Investigación Científica**

Revisado por:

MSc. Lic. Eri Donato España España

Coordinados por:

MSc. Ing. Roberto Alejandro Hernández Hernández
Guatemala, octubre de 2019

UNIVERSIDAD DE SAN CARLOS DE GUATEMALA



FACULTAD DE INGENIERÍA
ESCUELA DE ESTUDIOS DE POSTGRADOS

**MODELO DE VISIÓN Y MEMORIA ARTIFICIAL CAPAZ DE GENERAR UN
DIAGNÓSTICO MÉDICO POR PACIENTE CON DIFERENTE NÚMERO DE
IMÁGENES TOMOGRÁFICAS EN LA CIUDAD DE GUATEMALA,
GUATEMALA**

INFORME FINAL

POR

Lic. Diana María Letona Lee
Ing. Erick Alexander Ramírez Tebalán
Ing. Marvin Francisco Castillo Barrera

Med. Mildred Cristina Aspuac Sánchez
Ing. Luis Fernando Juárez Pacheco
Ing. Luis Fernando Leal Hernández

**Especialización en
Investigación Científica**

Guatemala, octubre de 2019

UNIVERSIDAD DE SAN CARLOS DE GUATEMALA
FACULTAD DE INGENIERÍA



NÓMINA DE JUNTA DIRECTIVA

DECANA	Inga. Aurelia Anabela Cordóva Estrada
VOCAL I	Ing. José Francisco Gómez Rivera
VOCAL II	Ing. Mario Renato Escobedo Martinez
VOCAL III	Ing. José Milton De León Bran
VOCAL IV	Br. Luis Diego Aguilar Ralón
VOCAL V	Br. Christian Daniel Estrada Santizo
SECRETARIA	Ing. Hugo Humberto Rivera Pérez

ESCUELA DE ESTUDIOS DE POSTGRADO

DIRECTOR	Maestro. Ing. Edgar Darío Álvarez Cotí
COORDINADOR	Maestro. Ing. Roberto Alejandro Hernández Hernández

AGRADECIMIENTOS

A la Universidad de San Carlos de Guatemala	Por ser una importante influencia en nuestras carreras y brindarnos la oportunidad de crecer personal y académicamente.
A la Escuela de Estudios de Postgrado de la Facultad de Ingeniería	Por la oportunidad de adquirir y expandir nuestros conocimientos, por ser herramientas en la transmisión de conocimiento y por ser nuestra casa por este tiempo. También por mejorar las percepciones que hoy en día me hacen la persona que soy.
A nuestros compañeros	Por ser un importante apoyo a lo largo de esta especialización y porque sin su apoyo, estos meses hubiesen sido más difíciles.
A nuestras familias	Porque ellos son quienes nos han permitido llegar donde estamos.
A todos	Los que de alguna manera hicieron posible este trabajo de graduación.

DEDICATORIA

A Dios

Por la oportunidad, el conocimiento, la ciencia y la sabiduría de lograr este sueño.

A nuestros padres

Por su apoyo y motivación.

A nuestras familias y amigos

Porque sin su apoyo, nada de esto hubiese sido posible.

ÍNDICE GENERAL

	Página
AGRADECIMIENTOS.....	I
DEDICATORIA.....	III
ÍNDICE GENERAL.....	V
ÍNDICE DE ILUSTRACIONES	XI
LISTA DE SÍMBOLOS	XIII
GLOSARIO	XV
RESUMEN	XIX
JUSTIFICACIÓN.....	XXI
OBJETIVOS	XXIII
INTRODUCCIÓN.....	XXV
1 INFORMACIÓN GENERAL	1
1.1 Aspectos generales	1
1.1.1 La ciudad de Guatemala	1
1.2 Antecedentes históricos	2
1.3 Definición del problema.....	3
1.3.1 Especificación del problema.....	3
1.3.2 Delimitación del problema	3
1.3.2.1 Pregunta principal de investigación.....	3
1.3.2.2 Preguntas complementarias de investigación	3
1.4 Ubicación de la ciudad de Guatemala	4
1.5 Localización de la ciudad de Guatemala	5
2 MARCO TEÓRICO.....	7

2.1	Inteligencia artificial	7
2.1.1	Modelo de inteligencia artificial	8
2.1.2	Memoria artificial.....	9
2.1.3	Visión artificial (Computer vision).....	9
2.1.4	Modelo de memoria y visión artificial	9
2.1.5	Campos de la inteligencia artificial	9
2.1.6	Aprendizaje automático (Machine learning).....	10
2.2	Diagnóstico médico	10
2.2.1	Diagnóstico médico con diferente número de imágenes.....	10
2.2.2	Imagen tomográfica.....	11
2.2.3	Diagnóstico médico con diferente número de imágenes tomográficas	12
2.2.4	Neuroimagen	13
2.2.5	Interpretando imagenología	14
2.3	Problemas cerebrales	14
2.3.1	Isquemia cerebral	14
2.3.2	Edema cerebral	15
2.3.3	Hemorragia cerebral.....	16
2.3.4	Masa cerebral.....	17
2.3.5	Fractura de cráneo	17
3	MARCO METODOLÓGICO	19
3.1	Universo.....	19
3.2	Variables.....	19
3.3	Muestreo	21

3.4	Tipo y diseño de investigación	22
3.5	Unidad de análisis	24
3.5.1	Unidad de análisis de muestreo	24
3.5.2	Unidad de análisis	24
3.5.3	Unidad de información.....	24
3.6	Hipótesis	24
3.7	Selección de los sujetos de estudio	25
3.7.1	Criterios de inclusión	26
3.7.2	Criterios de exclusión	26
3.8	Técnicas, procesos e instrumentos utilizados en la recolección de datos.....	26
3.8.1	Set de datos utilizado	27
3.8.2	Preprocesamiento.....	27
3.8.3	Enfoque y paradigma de inteligencia artificial usado.....	28
3.8.4	Arquitectura y diseño	29
3.8.5	Proceso de entrenamiento/aprendizaje	33
3.8.6	Hiper parámetros y configuraciones	37
3.8.7	Técnicas y métodos del marco teórico de inteligencia artificial.....	37
3.8.8	Tamaño y distribución de la muestra de imágenes	39
3.9	Procesamiento y análisis de datos.....	41
3.10	Límites de la investigación	43
3.10.1	Obstáculos (riesgos y dificultades).....	43
3.11	Aspectos éticos de la investigación	44

3.11.1 Principios éticos generales.....	44
3.11.1.1 Beneficencia y no maleficencia.....	44
3.11.1.2 Autonomía.....	44
3.11.1.3 Respeto por las personas.....	45
3.12 Categorías de riegos	45
3.12.1 Categoría I (sin riesgo).....	45
4 ESTUDIO TÉCNICO	47
4.1 Descripción del área de influencia	47
4.2 Misión del modelo.....	47
4.3 Visión del modelo	47
4.4 Organización del talento humano para la creación del modelo	48
4.5 Área de atención del modelo	48
4.6 Recursos físicos y tecnológicos del modelo	48
4.6.1 Recursos físicos	49
4.6.2 Recursos tecnológicos	49
4.7 Estudio de mercado.....	49
4.7.1 Capacidad.....	49
4.7.2 Demanda	49
4.7.3 Infraestructura.....	49
5 PROPUESTA DE SOLUCIÓN.....	51
5.1 Código.....	52
5.1.1 Prototipos edemas.....	52
5.1.2 Prototipos fractura	52

5.1.3	Prototipos hemorragia	52
5.1.4	Prototipos isquemia	52
5.1.5	Prototipos masa.....	53
5.1.6	Prototipos todos.....	53
5.1.7	Prototipos.....	53
5.2	Datos.....	54
5.2.1	Resumen TAC Cerebrales	54
5.3	Archivo de configuración “Convolutional_DNC.txt”	54
6	ANÁLISIS DE RESULTADOS	55
6.1	Experimento 1.....	55
6.2	Experimento 2.....	59
6.3	Resumen de resultados.....	65
7	COSTOS APROXIMADOS Y ANÁLISIS FINANCIERO	67
7.1	Costo de estudio.....	67
7.2	Presupuesto de mejora	70
7.3	Análisis financiero.....	71
7.4	Análisis financiero de costo-beneficio.....	72
7.5	Propuesta económica de proyecto.....	74
	CONCLUSIONES	75
	RECOMENDACIONES.....	77
	BIBLIOGRAFÍA	79
	E-GRAFÍA	81
	ANEXOS	85
	Anexo I Resumen de imágenes y diagnósticos	87

x

ÍNDICE DE ILUSTRACIONES

FIGURAS

	Página
Figura No. 1 Ciudad de Guatemala	1
Figura No. 2 Ubicación de la ciudad de Guatemala vista desde satélite	5
Figura No. 3 Localización de la ciudad de Guatemala vista desde satélite	6
Figura No. 4 Tomografía computarizada del cerebro	12
Figura No. 5 Arquitectura modelo Vgg19	31
Figura No. 6 Arquitectura del modelo combinado vgg19-LSTM	33
Figura No. 7 Diagrama de flujo del aprendizaje	36
Figura No. 8 Comparación de tomografías originales vs por síntesis artificial	39
Figura No. 9 Organigrama del talento humano para la creación del modelo	48
Figura No. 10 Vista del repositorio en sitio web	51
Figura No. 11 Notebook con código de Python	53
Figura No. 12 Función de costo/error de entrenamiento	55
Figura No. 13 Exactitud promedio de entrenamiento	56
Figura No. 14 Métricas de evaluación	57
Figura No. 15 Diagrama de arquitectura (alto nivel) del modelo combinado	59
Figura No. 16 Función de costo/error de entrenamiento	60
Figura No. 17 Exactitud de entrenamiento	61

Figura No. 18 Exactitud de validación	62
Figura No. 19 Métricas de evaluación de entrenamiento	63
Figura No. 20 Métricas de evaluación de validación	64
Figura No. 21 Histograma de Resultados	66

TABLAS

	Página
Tabla No. I Resumen de variables	20
Tabla No. II Proporción de positivos muestra para entrenamiento	40
Tabla No. III Proporción de positivos muestra para validación	40
Tabla No. IV Formulas	42
Tabla No. V Resumen de resultados	65
Tabla No. VI Recursos humanos	68
Tabla No. VII Recursos físicos, tecnológicos y materiales	69
Tabla No. VIII Recursos físicos, tecnológicos y materiales propuestos	70
Tabla No. IX Consideraciones de gastos de implementación	71
Tabla No. X Cálculo económico actual	72
Tabla No. XI Costos que representa no tener el modelo	73
Tabla No. XII Cálculo económico actual y relación costo-beneficio	73
Tabla No. XIII Distribución de datos de pacientes con diagnósticos validos	87

LISTA DE SÍMBOLOS

2D	Dos Dimensiones
3D	Tres Dimensiones
ADAM	Optimizador Adaptativo de Momento
AIT	Accidente isquémico transitorio
CAT	Tomografía Axial Computarizada
CPU	Unidad Central de Procesamiento
GPU	Unidad Procesadora de Gráficos
HIC	Hemorragia Intra Cerebral
IA	Inteligencia Artificial
IBM	International Business Machines
IC	Isquemia Cerebral
ICT	Isquemia Cerebral Transitoria
IOT	Internet de las Cosas
IRM	Imagen por resonancia magnética
LSTM	Long Short-Term Memory
RAM	Memoria de Acceso Aleatorio
RGB	Red Green Blue
RM	Resonancia Magnética
RN	Red Neuronal
RNC	Red Neuronal Convolucional
RNR	Red Neuronal Recurrente
TAC	Tomografía asistida por computadora
TC	Tomografía computarizada
TCE	Traumatismo Craneoencefálico
USAC	Universidad de San Carlos de Guatemala

GLOSARIO

Agente inteligente	Selecciona acciones que maximizan su desempeño basado en evidencia que ha adquirido y/o cualquier conocimiento que haya incorporado. (Stuart Russell, 2010, p. 34-37)
Aprendizaje Profundo	Técnicas “machine learning” que explotan muchas capas de procesamiento de información no lineal para la extracción y transformación de características, supervisada o no, y para el análisis y clasificación de patrones. (Deng & Yu, 2014, p. 199-200)
Aprendizaje supervisado	Proceso de aprendizaje caracterizado por lograrse con entrenamiento controlado por un agente externo (supervisor, maestro) que determina la respuesta que debería generar la red a partir de una entrada determinada. (Hernández López, 2006, p. 62)

Crowdsourcing	Del inglés <i>crowd</i> –multitud– y <i>outsourcing</i> –recursos externos–) traducido al español como colaboración abierta distribuida o externalización abierta de tareas, y consiste en externalizar tareas que, tradicionalmente, realizaban empleados o contratistas, dejándolas a cargo de un grupo numeroso de personas o de una comunidad, a través de una convocatoria abierta. (Crowdsourcing, s.f.)
Diferenciación automática	También llamada diferenciación algorítmica, consiste en la familia de técnicas similares, pero más generales que la retro propagación, para evaluar precisa y eficientemente derivadas de funciones numéricas expresadas como software. (Baydin, Pearlmutter, Radul, & Siskind, 2018, p. 1)
Edema	Acumulación de fluido en el espacio intersticial que ocurre cuando la filtración capilar excede los límites del drenaje linfático, produciendo signos y síntomas clínicos bastante notables. (Trayes, Studdiford, Pickle, & Tully, 2013)
Epoch	Termino en inglés, con traducción directa como época, que representa una unidad de tiempo de longitud predefinida en informática.

Hiper Parámetro	En estadísticas bayesianas, se refiere a un parámetro de una distribución previa. Se usa para distinguir los parámetros del modelo del sistema que está siendo analizado internamente (Hyperparameter, s.f.)
Machine Learning	Es el estudio científico de algoritmos y modelos estadísticos que sistemas de computadores usan para desarrollar tareas sin usar instrucciones explícitas, en su lugar, utilizan patrones e inferencia. Considerado parte de la inteligencia artificial. (Mitchell, 1997, p. 1)
Red Neuronal	Conocido como sistema conexionista, es un modelo computacional vagamente inspirado en el comportamiento observado en su homólogo biológico. Consiste en un conjunto de unidades, llamadas neuronas artificiales, conectadas entre sí para transmitirse señales. (Artificial Neural Network, s.f.)
Red Neuronal Convolutiva	Es un tipo de red neuronal artificial donde las neuronas corresponden a campos receptivos de una manera muy similar a las neuronas en la corteza visual primaria de un cerebro biológico. (Redes neuronales convolucionales, s.f.)

Red Neuronal Recurrente	Típicamente se le considera así a cualquier red cuyas neuronas envían señales de retroalimentación de otra. (Grossberg, 2013, p. 1)
Tomografía	Técnica exploratoria radiográfica que permite obtener imágenes radiológicas de una sección o un plano de un órgano. (Littleton)
VGG19	Red neuronal convolucional entrenada en más de un millón de imágenes de la base de datos de ImageNet. La red tiene 19 capas de profundidad y puede clasificar imágenes en más de mil categorías. (vgg19, s.f.)

RESUMEN

Avances recientes en investigación de inteligencia artificial han permitido a investigadores e ingenieros crear modelos aplicados a la medicina que han alcanzado y en algunos casos sobrepasado el nivel de exactitud de médicos expertos, por ejemplo, para detección de enfermedades de retina (Fauw, 2018, p. 24) esto a través del tipo de modelo conocido como red neuronal convolucional apropiado para imágenes.

En el caso de tomografías craneales recientemente se ha aplicado inteligencia artificial para crear modelos que diagnostican afecciones craneales de manera efectiva. Comúnmente comunica un enfoque de aprendizaje supervisado usando redes neuronales, entrenadas con un diagnóstico por imagen y luego combinando los diagnósticos de todas las imágenes (Chilamkurthy, 2018, p. 11) de manera manual a través de resúmenes estadísticos. Esto implica que se debe tener un registro médico con un diagnóstico por imagen; sin embargo, la forma de obtención de una tomografía cerebral incurre en una serie de tomas o cortes de diferentes ángulos, es por ello que un diagnóstico por imagen no se cumple en este tipo de prácticas médicas. Por tal razón se buscó la forma de crear un modelo de inteligencia artificial capaz de trabajar con un número variable de imágenes para un solo diagnóstico médico, y que fuera capaz de manejar distinta cantidad de imágenes por paciente.

Esto llevó a diseñar un nuevo modelo obtenido de la combinación de 2 premisas teóricas de inteligencia artificial. La primera que una red neuronal convolucional puede extraer patrones visuales de imágenes que pueden ser usados para realizar una predicción sobre ellas (diagnósticos). Y la segunda que una red neuronal recurrente puede extraer patrones temporales en datos organizados en secuencias y usarlos para realizar predicción.

El modelo fue diseñado con las siguientes dos premisas, bajo la hipótesis de investigación: Una red neuronal convolucional puede extraer patrones visuales de imágenes y luego estos patrones ser presentados en secuencia (imagen tras imagen) a una red neuronal recurrente para extraer patrones temporales de los patrones visuales que puedan ser usados para realizar una predicción (diagnóstico).

Financieramente se realizó el estudio con dos ingenieros en sistemas con conocimientos de inteligencia artificial por un periodo de 400 horas combinadas para el desarrollo del agente inteligente, por un periodo aproximado de tres meses, también se contó con los servicios de un médico con conocimientos de radiológica para que clasifique el inventario de imágenes de tomografías craneales donado, para que estos puedan ser utilizados para el entrenamiento del agente inteligente. Se contó también con resultados validados para el entrenamiento del agente inteligente.

Contando con el recurso humano y recursos materiales se implementa con un gasto aproximado de Q255,000.00.

JUSTIFICACIÓN

En los últimos años el uso de la inteligencia artificial, a nivel general y en muchas ramas de las ciencias aplicadas, “particularmente del subtipo aprendizaje profundo, ha sido posible por el uso de datos masivos etiquetados, junto con un crecimiento marcado del poder de procesamiento computacional y el almacenamiento en la nube, en todos los sectores” (Topol E. , 2019, p. 1)

Particularmente en el campo de la medicina, ha empezado a tener impacto en tres niveles:

1) para los médicos clínicos, por el uso de una interpretación de imágenes rápida y precisa, 2) para los sistemas de salud, mejorando el flujo de trabajo y el potencial para reducir errores, finalmente 3) para los pacientes, al permitirles procesar su propia información para mejorar su salud (Topol E. , 2019, p. 50)

Actualmente el acceso en la sala de urgencias de los hospitales públicos y privados de todas las regiones del país, para someterse a un análisis por tomografía al presentar traumatismos craneoencefálicos y síntomas neurológicos de focalización (principalmente) es limitado debido a la falta de recursos técnicos y personal especializado (radiólogos) lo cual dificulta la confirmación de diagnósticos y la toma de decisiones terapéuticas certeras. Esto afecta al paciente ya que existe un alto riesgo de que los síntomas varíen de un momento a otro durante el padecimiento y su vida se vea comprometida.

La inteligencia artificial puede ayudar a resolver problemas específicos como el análisis y procesamiento de imágenes. Se puede integrar como herramienta para ayudar a los profesionales de medicina, especialmente los involucrados en el área de tomografía, a proveer un mejor servicio a la población que requiere sus servicios.

Este proyecto de investigación se planteó con el objetivo de determinar el porcentaje de exactitud y rapidez que un agente inteligente puede alcanzar al generar un diagnóstico médico (medible de acuerdo con el promedio de certeza de registros médicos) a través del análisis de imágenes generadas por un tomógrafo con síntomas relacionados con hemorragia, isquemia o edema cerebral. La importancia de esta investigación radica en que, al igualar o mejorar el diagnóstico de un profesional experto en el área, se reducirán los errores humanos y el tiempo al momento de emitir un diagnóstico relacionado con los padecimientos cerebrales anteriormente mencionados. A partir de eso se reducirá el deceso de pacientes derivados de diagnósticos erróneos o de largos tiempos de espera por falta de disponibilidad de recursos.

Con una exitosa aplicación de la inteligencia artificial a la interpretación de tomografías cerebrales es posible ayudar a los médicos y médicos en entrenamiento a referir con mayor prontitud a un paciente con una patología que pueda comprometer su vida. También puede ayudar a reducir los costos de estos estudios, en especial en salud pública y en hospitales regionales. Así mismo, se podrían beneficiar los médicos porque tendrán una herramienta que servirá como complemento a su diagnóstico y podrán tomar decisiones más rápidas y certeras. Finalmente, los pacientes porque recibirán un mejor tratamiento y a costo más bajo.

OBJETIVOS

Objetivo general

Diseñar un modelo de visión y memoria artificial capaz de generar un diagnóstico médico por paciente con diferente número de imágenes tomográficas en la ciudad de Guatemala, Guatemala.

Objetivos específicos

1. Diseñar y desarrollar un modelo matemático computacional basado en álgebra lineal, cálculo multivariable, probabilidad y estadística, enmarcado en la rama de la inteligencia artificial, capaz de realizar diagnóstico médico de tomografías cerebrales sin importar el número de cortes de éstas.
2. Analizar los modelos de tipo red neuronal convolucional, red neuronal secuencial (recurrente) y un modelo combinado (convolucional – recurrente).
3. Evaluar los niveles de exactitud de los modelos tipo red neuronal convolucional, red neuronal secuencial (recurrente) y un modelo combinado (convolucional – recurrente), para la predicción de la presencia o ausencia de complicaciones médicas.

INTRODUCCIÓN

Las tomografías son una de las formas más comunes y efectivas para realizar diagnósticos de lesiones, anormalidades y afecciones en la región craneal, por ejemplo: hemorragia cerebral. Un diagnóstico rápido y certero puede ser de vital importancia incluso para salvar la vida de un paciente.

La interpretación de tomografías se realiza por médicos expertos entrenados, uno de los problemas en Guatemala es que la demanda de expertos supera la oferta de estos lo cual puede llevar a poner en riesgo a los pacientes, además de esto se dificulta más el tener una segunda opinión (o más) para emitir un solo diagnóstico como a veces ocurre en otros ámbitos de la medicina.

Para apoyar a los médicos con la exactitud en la interpretación de tomografías craneales especialmente en la identificación de hemorragias, isquemias, fracturas, masas y edemas, se recurrió a la Inteligencia Artificial como una alternativa.

La inteligencia artificial es una rama de las ciencias de la computación que alimentada e inspirada por otras ciencias como matemática y estadística permite crear modelos computacionales capaces de trabajar y realizar predicciones sobre imágenes, esto a través de la sub rama conocida como aprendizaje de máquina aplicado a visión por computadora, que teóricamente nos dice que es posible entrenar un algoritmo de visión por computadora usando imágenes y una descripción del contenido de la imagen (llamada etiqueta) creada por humanos.

Basado en esta premisa teórica, en este trabajo de investigación con enfoque cuantitativo, experimental y deductivo se creó un modelo de inteligencia artificial aplicado a visión por computadora que luego de ser entrenado con imágenes (tomografías craneales) y la etiqueta asociada (diagnóstico médico) proporcionadas por un centro de diagnóstico radiológico, fuera capaz de realizar diagnóstico de afecciones craneales.

Por esto se desarrolló un modelo matemático de Inteligencia Artificial convolucional recurrente a partir de estudios previamente diagnosticados.

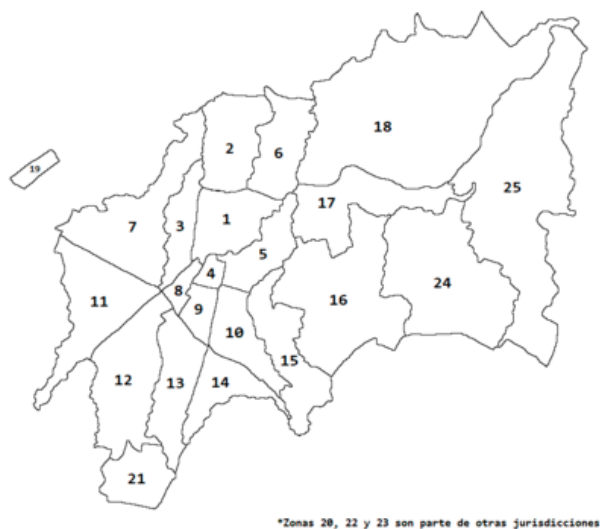
1 INFORMACIÓN GENERAL

1.1 Aspectos generales

1.1.1 La ciudad de Guatemala

Capital de Guatemala, ubicada en el Valle de la Ermita desde 1773, a una altura entre 1,500 y 1,600mts sobre el nivel del mar con una temperatura que oscila entre 10 y 25°C. Se encuentra dividida geográficamente en 25 zonas, aunque las zonas 20, 22 y 23 son parte de otros municipios. Posee pocas vías de acceso debido a los accidentes geográficos que la rodean

Figura No. 1 Ciudad de Guatemala



*Zonas 20, 22 y 23 son parte de otras jurisdicciones

Fuente: Wikipedia 2019.

1.2 Antecedentes históricos

La ciudad de Santiago de los Caballeros de Guatemala, como era conocida en la colonia la capital de la Capitanía General de Guatemala, ha cambiado de lugar durante cuatro ocasiones, cambiándose por última vez de lugar en 1775, a el valle de la Ermita, y con nombre oficial de Nueva Guatemala de la Asunción.

Actualmente a la ciudad se encuentra en el departamento de Guatemala, teniendo límites con los municipios de San Miguel Petapa, Villa Nueva y Villa Canales al sur, con Mixco, San Juan Sacatepéquez y Chinautla al occidente, Santa Catarina Pinula y San José Pinula y Santa Catarina Pinula al oriente, y San Raymundo al norte. Su distribución actual de zonas geográficas en espiral ha sido replicada en el resto del país, empezando por la zona 1 y terminando en la zona 25.

Es considerada como la ciudad más grande de América Central debido su gran densidad poblacional, ya que tiene una gran cantidad de habitantes comparada con su relativamente corta extensión territorial. Con clima tropical debido a su ubicación geográfica, las lluvias pueden presentarse a lo largo de todo el año. Existe un alto grado de centralización en el país, por lo que la mayoría de las oficinas de negocios y gubernamentales se ubican dentro de esta, o en menor grado, en los suburbios de los alrededores.

En cuanto a la Universidad de San Carlos de Guatemala, esta ha tenido diferentes sedes y actualmente se encuentra en la zona 12 de la ciudad de Guatemala, con sedes a nivel departamental y un centro universitario metropolitano en la ciudad de Guatemala también.

1.3 Definición del problema

1.3.1 Especificación del problema

Se carece de un instrumento para apoyar a los médicos con interpretación y diagnóstico de tomografías craneales para tener un mayor nivel de exactitud al identificar hemorragias, isquemias fracturas, masas y edemas.

1.3.2 Delimitación del problema

El estudio fue realizado en el área de Innovación y transferencia tecnológica y emprendimiento del sector de conocimiento de salud y tecnología. Su delimitación temporal es de febrero a octubre del 2019. El lugar es la ciudad de Guatemala, en el departamento de Guatemala, y la unidad de análisis son modelos matemáticos. El problema general es que no se tiene una inteligencia artificial que interprete las tomografías cerebrales normales y de pacientes con hemorragia, isquemia, fracturas, masas y edema cerebral.

1.3.2.1 Pregunta principal de investigación

¿Es posible diseñar un modelo de visión y memoria artificial capaz de generar un diagnóstico médico por paciente con diferente número de imágenes tomográficas en la ciudad de Guatemala, Guatemala?

1.3.2.2 Preguntas complementarias de investigación

¿Se puede desarrollar un modelo matemático computacional basado en álgebra lineal, cálculo multivariable, probabilidad y estadística, enmarcado en la rama de la inteligencia artificial, capaz de realizar diagnóstico médico de tomografías cerebrales sin importar el número de cortes de éstas?


¿Cómo son los modelos de tipo red neuronal convolucional, red neuronal secuencial (recurrente) y un modelo combinado (convolucional – recurrente)?

¿Cuáles son los niveles de exactitud de los modelos tipo red neuronal convolucional, red neuronal secuencial (recurrente) y un modelo combinado (convolucional – recurrente), para la predicción de la presencia o ausencia de complicaciones médicas?

1.4 Ubicación de la ciudad de Guatemala

Se encuentra como cabecera departamental del país en el departamento de Guatemala, y siendo también la capital del país. Todas las carreteras del país empiezan la numeración de kilómetros desde el centro de la ciudad.

Figura No. 2 Ubicación de la ciudad de Guatemala vista desde satélite




Fuente: Google Maps 2019.

1.5 Localización de la ciudad de Guatemala

La ciudad de Guatemala se encuentra en lo que es en sí, el municipio de Guatemala, en el departamento de Guatemala. Es posible acceder por cualquier vía principal del país. Su ubicación en coordenadas de latitud y longitud es 15°47'0.5" N 90°13'50.7" O.

Figura No. 3 Localización de la ciudad de Guatemala vista desde satélite



Fuente: Google Maps 2019.

2 MARCO TEÓRICO

En esta sección se da a conocer los conceptos necesarios para la comprensión del desarrollo de esta investigación relacionados a la inteligencia artificial, diagnóstico médico y problemas cerebrales.

2.1 Inteligencia artificial

La inteligencia artificial es una rama de las ciencias de la computación, definida como “el diseño y construcción de agentes inteligentes que perciben el ambiente y toman acciones que afectan ese ambiente.” (Stuart Russell, 2010, p. 1)

En la actualidad existen varias definiciones de inteligencia artificial, a continuación, se describen algunas:

- Actuar humanamente: Con enfoque en la prueba de Turing, que fue diseñada para proporcionar una definición operacional de inteligencia. Al final la prueba se basa en la posibilidad de distinguir o no respuestas que vengan de una computadora o una persona.
- Pensar humanamente: Con enfoque en el modelo cognitivo, tratando de determinar la manera en que los humanos piensan. Utiliza la ciencia cognitiva como base.
- Actuar racionalmente: Con enfoque en las reglas del pensamiento. Basada en la tradición de la lógica dentro de las ciencias de la computación.
- Pensar racionalmente: Con enfoque en el agente racional. Un agente es algo que actúa, un agente racional es el que actúa para obtener el mejor resultado, o en caso de incertidumbre, el mejor resultado esperado.

En resumen, existen dos ejes para definir inteligencia artificial, en uno de ellos existen los procesos de pensamiento y razonamiento, y en el otro extremo el pensamiento, mientras que el otro eje se define la racionalidad, la capacidad de hacer lo correcto, basado en lo que conoce.

Históricamente, estos cuatro modelos han sido seguidos con diferentes métodos. Mientras que los enfoques centrados en el humano deben ser en parte ciencia empírica, involucrando observaciones e hipótesis sobre el su comportamiento. Caso contrario con el enfoque racionalista, que es una combinación de matemáticas e ingeniería. Aun así, ambos grupos se asisten entre sí en la práctica. (Stuart Russell, 2010, p. 1-7)

2.1.1 Modelo de inteligencia artificial

Relación numérica entre 2 entidades matemáticas creado usando técnicas de inteligencia artificial.

Es un tipo de modelo computacional, derivado de la aplicación de la teoría relacionada a la inteligencia artificial, en un software capaz de realizar una tarea y obtener resultados que puedan ser comparables a lo que realiza un ser humano. Los modelos computacionales requieren de grandes capacidades de procesamiento para lograr cumplir su tarea.

2.1.2 Memoria artificial

El concepto de memoria asociada ha sido la esencia de las redes neuronales donde los valores de los pesos de conexión almacenan información sobre los datos de entrenamiento. Se refiere a memoria artificial a la forma de capturar y estructurar información durante un periodo de tiempo a la vez que una red neuronal mapea esa información entre las entradas y salidas. Tal es el caso de Long Short-Term Memory (LSTM) refiriéndose al uso de gran memoria de corto plazo, siendo una red neuronal recurrente que posee conexiones de retroalimentación. (Pratik Prabhanjan Brahma, 2018, p. 1)

2.1.3 Visión artificial (Computer vision)

Campo interdisciplinario que busca que las computadoras obtengan una comprensión de alto nivel de imágenes o videos digitales. Desde la perspectiva de la ingeniería, busca automatizar las tareas que puede realizar el sistema visual humano. (Ballard & Brown, 1982, p. 6)

2.1.4 Modelo de memoria y visión artificial

Se define como un modelo de memoria y visión artificial al que combina las características de la persistencia de conocimiento obtenido por medio de una red neuronal con las características de análisis de imágenes que son parte de la visión artificial.

2.1.5 Campos de la inteligencia artificial

Los campos de aplicación de la inteligencia artificial son los siguientes:

- Aprendizaje automático (Machine learning)
- Aprendizaje por refuerzo (Reinforcement learning)
- Visión de computadora (Computer vision)

- Robótica
- Procesamiento de lenguaje natural (Natural language processing)
- Sistemas colaborativos
- Crowdsourcing y computación humana
- Internet de las cosas (IoT)

2.1.6 Aprendizaje automático (Machine learning)

El termino es acreditado a Arthur Samuel de IBM, quien en el año 1959 propuso que fuera posible enseñar a las computadoras a aprender todo lo que ellas necesitan saber acerca del mundo y como llevar a cabo tareas por sí mismas. Se entiendo como una aplicación de la inteligencia artificial.

Surge del reconocimiento de patrones y la teoría de que las computadoras pueden aprender sin ser programadas para desempeñar tareas específicas. Esto incluye técnicas tales como: métodos bayesianos, redes neuronales, programación de lógica inductiva, procesamiento de lenguaje natural, árboles de decisión, y aprendizaje por refuerzo. (Panesar, 2019, p. 3)

2.2 Diagnóstico médico

Conclusión a la que llega un médico luego de haber evaluado ordenada y metódicamente a un paciente, y haber analizado los datos subjetivos y objetivos obtenidos en la evaluación, pudiendo apoyar su conclusión en imágenes diagnósticas como radiografías, tomografías, entre otras.

2.2.1 Diagnóstico médico con diferente número de imágenes

Conclusión médica basada o apoyada en dos o más imágenes diagnósticas.

2.2.2 Imagen tomográfica

Se toma como base dado que “La tomografía computarizada (TC; otros términos incluyen tomografía asistida por computadora [CAT]) ha estado disponible comercialmente desde 1973.” (Bela Ajtai, 2016, p. 411)

El término tomografía (es decir, corte o sección) se refiere a un proceso para generar cortes de imágenes bidimensionales (2D) de un órgano, o en tres dimensiones (3D). La tomografía computarizada se basa en la absorción diferencial de rayos X por diversos tejidos.

Los rayos X son ondas electromagnéticas con longitudes de onda que caen en el rango de 10 a 0.01 nanómetros en el espectro electromagnético.

Los rayos X también se pueden describir como fotones de alta energía, con energías correspondientes que varían entre 124 y 124,000 voltios de electrones, respectivamente. Los rayos X en el rango más alto de energías, conocidos como rayos X duros, se usan en imágenes de diagnóstico debido a su capacidad de penetrar en el tejido, pero (hasta cierto punto) también son absorbidos o dispersados de manera diferencial por varios tejidos, lo que permite la generación de contraste de imagen. (Bela Ajtai, 2016, p. 411,412)

Comúnmente cuando se piensa en tomografías se considera su carácter de uso médico, pero también tiene otras aplicaciones, como por ejemplo la tomografía sísmica. Sin embargo, esto se encuentra fuera del objeto de estudio actual. Dentro de la medicina probablemente la tomografía axial computarizada y la resonancia magnética son las más conocidas, sino es que las más usadas.

Es utilizada en prácticamente todo el cuerpo, pero su uso se aprecia más en las áreas cerebrales, abdominales y torácicas, y en las salas de urgencia la más indicada es la cerebral.

La tomografía cerebral (también conocida como craneal o de cabeza) es un estudio de imagen no invasivo utilizado como complementación diagnóstica. Esta utiliza los rayos X en forma de espectro continuo, para obtención de imágenes tridimensionales en forma de cortes de hasta 8 mm de grosor. Es útil para detectar diferentes alteraciones a nivel cerebral como hemorragias, tumores, entre otras. (Hernandez Cruz, 2019)

Figura No. 4 Tomografía computarizada del cerebro



Fuente: Radiology Info 2019.

2.2.3 Diagnóstico médico con diferente número de imágenes tomográficas

Conclusión médica basada o apoyada en pocas o muchas imágenes tomográficas.

2.2.4 Neuroimagen

La selección adecuada de la terapia en TCE (traumatismo craneoencefálico), manejo quirúrgico y médico, depende tanto de los datos clínicos como de los resultados de las imágenes. Con conocimiento básico de fisiopatología, se puede entender cómo aparece una condición particular en las imágenes.

La radiografía simple proporciona muy poca información en pacientes con TCE. Las películas simples pueden usarse para buscar cuerpos extraños o visualizar fracturas.

Sin embargo, la tomografía computarizada (TC) y la resonancia magnética (RM) son esenciales para el diagnóstico preciso y el manejo posterior de los pacientes con TCE. Las imágenes de pacientes con TCE en el contexto agudo a menudo comienzan con una TC del cerebro sin contraste.

La TC helicoidal (la ruta helicoidal da como resultado un conjunto de datos tridimensionales, que luego se puede reconstruir en imágenes secuenciales para una pila.) es útil en pacientes que han sufrido politraumatismos además de lesiones cerebrales.

La imagen por resonancia magnética (IRM) desempeña un papel complementario en la lesión cerebral. La resonancia magnética es muy útil para la detección de lesiones ocultas, el seguimiento y el tratamiento a largo plazo de pacientes con lesiones cerebrales traumáticas. En comparación con la TC, la IRM proporciona detalles exquisitos de los tejidos blandos y también ayuda en la evaluación del tronco encefálico, la base del cráneo y los nervios craneales. Muestra particularmente bien la fosa posterior, que a menudo está oscurecida por un artefacto de endurecimiento del haz que ocurre con la TC.

La resonancia magnética se puede obtener en el contexto agudo si hay hallazgos clínicos desproporcionados con los hallazgos de la TC, lo que sugiere Daño axonal difuso o accidente cerebrovascular. (Prabhakar, 2017, p. 545 - 547)

2.2.5 Interpretando imagenología

Al interpretar una tomografía computarizada del cerebro, se debe prestar especial atención a las convexidades cerebrales y al efecto de masa, incluidas las estructuras de la línea media, la presencia de desplazamiento, los ventrículos, las cisternas basales y la presencia de hernia. La TC también ofrece exquisitos detalles óseos. Las fracturas de cráneo, particularmente las fracturas deprimidas, a menudo anuncian lesiones cerebrales subyacentes. (Prabhakar, 2017, p. 547)

2.3 Problemas cerebrales

2.3.1 Isquemia cerebral

La isquemia cerebral es causada por la reducción del suministro de sangre a la microcirculación; es decir el flujo sanguíneo es insuficiente en ciertas áreas del cerebro.

La isquemia causa deterioro del metabolismo cerebral, pérdida de la glucólisis aeróbica, acumulación intracelular de iones de sodio y calcio, liberación de neurotransmisores excitotóxicos, elevación de los niveles de lactato con acidosis local, producción de radicales libres, hinchazón celular, hiperactivación de lipasas y proteasas y muerte celular. (Daroff, Jankovic, Mazziotta, & Pomeroy, 2016, p. 920)

Debido a sus altas demandas metabólicas, la función cerebral depende completamente del suministro de sangre y oxígeno. Los síntomas clínicos se

producen cuando el suministro de sangre global o regional cae por debajo de los 50 ml críticos por 100 g por minuto. (Goldman & Schafer, 2019, p. 1496).

Cuando la isquemia cerebral es transitoria se denomina accidente isquémico transitorio (AIT) y se produce “cuando se detiene el flujo sanguíneo a una parte del cerebro por un breve período de tiempo. Una persona tendrá síntomas similares a un accidente cerebrovascular hasta por 24 horas.

Los síntomas pueden durar entre 1 y 2 horas.” (MedlinePlus, 2019). En ocasiones esta isquemia puede prolongarse y ocasionar un infarto cerebral con secuelas permanentes.

Es importante resaltar que “Tanto la IC como la ICT son marcadores de riesgo elevado de incapacidad y riesgo de muerte.” (Arauz-Góngora, Coral-Casas, & Leyva-Rendón, 2005, p. 255).

Solamente en Estados Unidos existen más de 300,000 nuevos casos de isquemia cerebral transitoria anualmente, y “alrededor de 15 a 20% de los pacientes con un infarto cerebral tienen historia de ICT “. (Arauz-Góngora, Coral-Casas, & Leyva-Rendón, 2005, p. 250)

2.3.2 Edema cerebral

Es el aumento de agua en el tejido cerebral que ocasiona inflamación, este cambio dentro del cráneo cerrado clínicamente se presenta como el síndrome de hipertensión intracraneal, manifestándose con papiledema, cefalea progresiva, náuseas, vómitos, trastornos de la conciencia y coma.

“El cerebro edematoso puede desplazar y comprimir las estructuras cerebrales, lo que reduce la perfusión cerebral y, en última instancia, conduce al infarto y hernia cerebral, causas comunes de muerte”. (K.M.A. Welch, 2017, p. 153-156).

Los edemas se pueden dividir en vasogénico, intersticial y citotóxico. El primero se caracteriza por el rompimiento de la barrera hematoencefálica, el citotóxico es causado por cualquier lesión celular y está relacionado con isquemia. El ultimo tipo corresponde al aumento de la presión del líquido cefalorraquídeo, siendo un ejemplo la hidrocefalia. La tomografía de cráneo es capaz de detectar el edema como una señal hipodensa anormal cuando se trata de un edema focal. Cabe destacar que la tomografía no es muy útil si el edema es de tipo citotóxico. (Esqueda-Liquidano, 2014, p. 585)

2.3.3 Hemorragia cerebral

También llamada hemorragia intracerebral. La hemorragia intracerebral (HIC) es responsable del 10 al 15% de todos los accidentes cerebrovasculares con morbilidad y mortalidad significativas. La HIC puede ser primaria o secundaria.

La primaria se produce cuando un vaso sanguíneo pequeño o grande vulnerable se rompe sin una razón identificable de debilidad estructural y la sangre se filtra bajo presión, causando un daño considerable a las estructuras circundantes. Una HIC secundaria ocurre cuando una causa identificable subyacente produce una hemorragia parenquimatosa. Las causas incluyen aneurisma, malformación arteriovenosa, transformación hemorrágica del ictus isquémico arterial o venoso, traumatismo, coagulopatía y hemorragia de una lesión neoplásica parenquimatosa primaria o secundaria subyacente.

Cualquiera sea la causa, habrá consecuencias de daño neuronal de grado variable. (K.M.A. Welch, 2017, p. 148)

2.3.4 Masa cerebral

Crecimiento anormal de células cerebrales.

2.3.5 Fractura de cráneo Pérdida de continuidad o ruptura de un hueso de la bóveda craneana, puede ser completa o parcial.

3 MARCO METODOLÓGICO

En esta sección se explican los detalles técnicos de los modelos utilizados incluyendo: arquitectura, hiper parámetro, configuraciones, métodos y técnicas de inteligencia artificial usadas, así como el diseño experimental y recopilación de datos cuantitativos.

3.1 Universo

Se consideraron múltiples estudios tomográficos cerebrales de pacientes, de una institución médica, para crear y desarrollar un nuevo modelo de visión y memoria artificial.

3.2 Variables

Modelos (arquitectura general, configuraciones específicas): cualitativa, policotómica, independiente. Exactitud de cada modelo: cuantitativa, continua, dependiente. Las variables independientes son los modelos: su arquitectura general y configuraciones específicas, como también las dependientes métricas como la exactitud de cada modelo.

Tabla No. I Resumen de variables

NOMBRE	TIPO	VALOR	DESCRIPCIÓN
Modelo convolucional	Arquitectura	Vgg19 <ul style="list-style-type: none"> Modelo pre entrenado 512 neuronas de salida 	Modelo de la etapa de visión artificial.
Modelo recurrente	Arquitectura	LSTM <ul style="list-style-type: none"> 512 neuronas de entrada 512 neuronas ocultas. 5 neuronas de salida 	Modelo de la etapa de memoria artificial.
Tasa de aprendizaje inicial	Hiper parámetro	0.0003	Valor inicial para controlar cuanto actualiza la IA su conocimiento durante el entrenamiento.
Tasa de aprendizaje final	Hiper parámetro	0.00001	Valor final para controlar cuanto actualiza la IA su conocimiento durante el entrenamiento.
Optimizador por gradiente Adaptivo	Optimizador estocástico	Adam	Algoritmo de optimización para minimización del error entre los diagnósticos reales y los diagnósticos del modelo.

Fuente: Realización propia 2019.

3.3 Muestreo

Al no poder utilizar todos los exámenes de tomografías cerebrales de Guatemala, se tomó una muestra proporcionada por un centro de diagnóstico, para desarrollar el modelo de inteligencia artificial. Se evaluó dependiendo de la exactitud del programa, de qué tamaño necesita ser la muestra.

Para calcular la muestra se tomó un nivel de confianza del 95% con un error del 5%. De la cantidad de imágenes que se obtuvieron, solamente se utilizaron 1031 que cumplieron con los requisitos de anonimidad y diagnóstico disponible. Sobre estas es que calcularemos el valor de nuestra muestra. Sobre estas imágenes tenemos una seguridad muy alta que serán útiles para el entrenamiento del modelo, por lo tanto, consideramos que un 99% de estas serán usadas. La fórmula que utilizaremos se describe a continuación:

$$n = \frac{k^2 pqN}{e^2(N-1) + k^2 pq}$$

n: es el tamaño de nuestra muestra a determinar

p: variabilidad positiva (0.99)

q: variabilidad negativa (0.01)

N=tamaño de la población

e=Error muestral que se considera (0.05)

k=Constante de nivel de confianza, en este caso es del 95%, por lo tanto 1.96

El resultado de la evaluación del valor de n sería el siguiente:

$$n = \frac{(1.96)^2(0.99)(0.01)(1031)}{(0.05)^2(1031 - 1) + (1.96)^2(0.99)(0.01)} = \frac{39.21}{0.098} \approx 400$$

Por lo tanto, se determina que para la investigación son necesarias al menos 400 de estas imágenes, pero la muestra real que se necesita para poder aplicar el modelo nos la proporcionara la experimentación con este.

3.4 Tipo y diseño de investigación

La investigación se clasifica cómo:

- **Analítica descriptiva:** ya que describe el proceso de experimentación y el modelo encontrado.
- **Cuantitativa (vs cualitativa):** ya que basada en matemática y estadística, los datos generados por los experimentos son cuantitativos.
- **Metodología Deductiva (vs inductiva):** ya que se procedió de la teoría a la experimentación y recolección de datos experimentales; no de la recolección/muestreo de datos a la teoría, como ocurre en la metodología inductiva.
- **Experimental (vs de campo):** basado en el marco teórico se procedió a plantear hipótesis de modelos útiles y se experimentó poniendo a prueba las hipótesis a través de la captura y análisis de datos cuantitativos.

El diseño ejecutó múltiples experimentos utilizando distintos modelos, arquitecturas, hiper parámetros, configuraciones, métodos y técnicas de AI capturando para todo experimento los datos cuantitativos resultantes, principalmente métricas de evaluación de modelos de clasificación: exactitud, precisión, sensibilidad, medida f1.

Los experimentos se realizaron utilizando las siguientes herramientas de software:

- Python 3: Lenguaje de programación.
- Pytorch: librería de Python encasillada en la categoría de software auto diferenciable que permite y facilita el desarrollo, experimentación e investigación de algoritmos de inteligencia artificial.
- Jupyter: herramienta ampliamente utilizada en programación científica y numérica ya que facilita combinar código de programación, anotaciones y texto narrativo, imágenes, visualizaciones y notación matemática.
- Matplotlib: librería de Python utilizada para crear dinámica y programáticamente gráficas y visualizaciones de datos para facilitar su análisis.
- NumPy: librería de Python utilizada para realizar operaciones matemáticas y numéricas, por ejemplo, álgebra lineal y manipulación de estructuras de datos multidimensionales.
- Pandas: librería de Python utilizada para facilitar el análisis y manipulación de datos.

Además del software es importante mencionar el hardware utilizado ya que se requiere para poder ejecutar los experimentos al utilizarse componentes específicos, siendo específicos: unidades procesadoras de gráficos:

- Unidad procesadora de gráficos nVidia Titan XP
- Unidad procesadora de gráficos nVidia GTX 1060
- 32 GB de RAM
- Procesador Intel Core i7

Descripción, objetivo o propósito: Proponer un modelo matemático, basado en álgebra lineal, cálculo multivariable, probabilidad y estadística, y computacional, enmarcado en la rama de inteligencia artificial, capaz de realizar diagnóstico médico sobre tomografías craneales que sean explícitamente programados en un software.

3.5 Unidad de análisis

3.5.1 Unidad de análisis de muestreo

Estudios de tomografías cerebrales.

3.5.2 Unidad de análisis

Modelos de inteligencia artificial.

3.5.3 Unidad de información

Resultados de diagnósticos de estudios de tomografías cerebrales.

3.6 Hipótesis

Basado en el marco teórico se formularon nuevas hipótesis para poner a prueba de manera experimental y así proveer soporte y evidencia empírica con el objetivo de obtener conclusiones específicas a partir de premisas generales. En este caso se partió de 2 premisas teóricas de inteligencia artificial:

1. Un modelo de red neuronal convolucional es capaz de extraer características y patrones espaciales de imágenes para realizar predicciones del contenido de estas.
2. Un modelo de red neuronal recurrente es capaz de extraer características y patrones a través del tiempo en secuencias de información para realizar predicciones de la secuencia.

H0: Esto lleva a plantear las siguientes hipótesis (de lo más general a lo más específico):

- La inteligencia artificial usando un modelo de red neuronal convolucional puede aprender a partir de imágenes, a diagnosticar una tomografía cerebral.
- Un modelo del tipo red neuronal convolucional puede aprender a extraer características relevantes de imágenes, en este caso tomografías, que ayuden a realizar una predicción de la presencia o ausencia de complicaciones médicas extrayendo características y patrones espaciales por imagen.
- Un modelo de red neuronal secuencial (recurrente) puede tomar como entrada una secuencia de las características extraídas por un modelo de red neuronal convolucional para realizar una predicción general por paciente.
- Un modelo combinado (convolucional-recurrente) puede aprender a realizar un diagnóstico único por paciente independiente del número de tomografías (posiblemente variable) que se posea de cada uno.

3.7 Selección de los sujetos de estudio

Modelos matemáticos computacionales de inteligencia artificial.

3.7.1 Criterios de inclusión

Modelos adecuados para el procesamiento de datos espaciales como:

- modelos convolucionales
- modelos secuenciales, ya que, por cada paciente y diagnóstico, se tiene una secuencia de imágenes.

3.7.2 Criterios de exclusión

- Modelos que se prueban y no son funcionales.
- Modelos no adecuados para la estructura de los datos (perceptrones multicapa o modelos lineales como regresión logística).

3.8 Técnicas, procesos e instrumentos utilizados en la recolección de datos

Se realizaron múltiples experimentos bajo distintas condiciones y variables, muchos han resultado fallidos desde el punto de vista de no generar datos resultantes que parezcan proveer evidencia a favor de las hipótesis. Se capturaron, graficaron y analizaron datos cuantitativos resultantes de algunos de los experimentos exitosos, específicamente métricas de evaluación de los modelos usados de manera estándar en el desarrollo e investigación de IA: exactitud, precisión, sensibilidad y puntaje f1.

Las variables y condiciones que han sido variadas y evaluadas experimentalmente incluyen:

- Arquitectura de modelos.
- Hiper parámetros
- Técnicas y métodos del marco teórico de inteligencia artificial.
- Tamaño y distribución de la muestra de imágenes (y sus respectivos diagnósticos) utilizada para entrenar y evaluar los modelos.

3.8.1 Set de datos utilizado

Los datos usados en los experimentos para entrenar los modelos han sido obtenidos gracias a la colaboración de un médico especialista que ha proveído tanto imágenes como los diagnósticos asociados a estas imágenes.

El set de datos completo contiene información de 1,142 pacientes (anonimizados), cada paciente con un número variable de imágenes que cuentan un total de 16524 total de imágenes y un promedio de 23 por paciente. El tamaño final de la muestra es menor a esto debido a filtrado realizado el cual describimos en la siguiente sección.

Commented [U1]: Actualizar este valor

Commented [U2]: Actualizar este valor

3.8.2 Preprocesamiento

Se utilizó poco preprocesamiento en los datos y se resume en 3 tareas:

- Se descartaron estudios de pacientes sin diagnóstico.
- Se descartó estudios de pacientes con más de 50 imágenes ya que esto ocasionaba que los experimentos fallaran por sobrepasar la cantidad de memoria disponible en la computadora utilizada.

- Se replicó 3 veces la matriz de bytes que representa a cada imagen debido a que el modelo convolucional usado espera imágenes de 3 canales (RGB) y las tomografías solo poseen 1 canal. Cada matriz de bytes se ha convertido a un cubo.
- Se descartaron imágenes a color y las provenientes de otros estudios.

Luego del preprocesamiento el tamaño de la muestra quedó 715 pacientes y se utilizaron las imágenes del 90% de pacientes para entrenar y experimentar con los modelos y el 10% restante para evaluar y realizar la selección, esto realizando una separación y selección aleatoria para cada submuestra. El tamaño final fue este, pero a lo largo del proyecto se trabajó con muestras de tamaño menor según se iban adquiriendo.

3.8.3 Enfoque y paradigma de inteligencia artificial usado

Los experimentos han sido realizados a través del enfoque conocido como “Machine Learning” (aprendizaje de máquina o aprendizaje automático). Específicamente en su subtipo conocido como “aprendizaje supervisado”, que busca crear una función matemática $y = f(X)$, a partir de ejemplos de la realidad de esta función.

En este caso concreto “ X ” representa imágenes cerebrales (tomografías), “ y ” representa diagnósticos de pacientes. Se aplica un proceso de optimización matemática llamado “gradiente en descenso” (basado en álgebra lineal y cálculo multivariable) con el objetivo de minimizar la diferencia entre la realidad (diagnósticos proveídos por el médico) y las predicciones obtenidas con el modelo de inteligencia artificial. Con esto se busca que la computadora sea capaz de identificar la función matemática que relaciona cuantitativamente a “ X ” (tomografías) con “ y ” (diagnósticos).

Aunque ya se ha usado inteligencia artificial en el pasado para tareas similares y otras tareas médicas basadas en imágenes, este enfoque requiere que por cada imagen (o valor X) se posea un valor esperado o a predecir (o valor “ y ”) para poder aproximar la función $y = f(X)$. Por ejemplo, en el contexto de este proyecto significaría que por cada imagen se posea un diagnóstico. Pero para este proyecto y en muchos otros casos de diagnóstico médico se cuenta con muchas imágenes por paciente (con un número variable de estas para diferentes pacientes) y un solo diagnóstico, lo cual plantea el reto de crear un modelo que difiere de las técnicas tradicionales (de un “ x ” por cada “ y ”).

Se posee por cada “ y ” un número variable de “ X ”, por lo tanto, buscamos proponer y desarrollar un modelo de la forma $y = f(X_1 \dots X_n)$, con “ n ” desconocido y variable.

3.8.4 Arquitectura y diseño

Fueron utilizadas múltiples arquitecturas en distintos experimentos, se describen los 2 con los mejores resultados cuantitativos, la arquitectura consiste en la combinación de un modelo convolucional y un modelo secuencial, los cuales comúnmente se usan de manera independiente y en distintos tipos de problemas.

Algunas de las arquitecturas usadas en experimentos no exitosos fueron:

- Red convolucional de una capa usada como controlador de una computadora neuronal diferenciable (Alex & Wayne, 2016)
- ResNet18 (He, Zhang, Ren, & Sun, 2015) conectada a una red LSTM.

Las 2 arquitecturas con mejores resultados cuantitativos (a favor de nuestras hipótesis) comparten características y detalles de diseño tales como:

Utilizan un modelo convolucional pre entrenado (congelando capas convolucionales iniciales) con la etapa final (capas densas o completamente conectadas) modificadas (y no congeladas), este modelo se encarga de la extracción de características y patrones visuales en las imágenes, a esta etapa se le llamará: etapa de visión artificial. Los 2 mejores resultados utilizan una capa densa de 512 neuronas en remplazo de las capas originales en el modelo Densenet121.

Commented [GU3]: Actualizar cuando ya se tengan los resultados definitivos

Utilizan como parte recurrente una red tipo LSTM (Hochreiter & Schmidhuber, 1997) la cual recibe una secuencia (de tamaño variable) de características y patrones visuales extraídos por la etapa convolucional, almacena en su memoria información relevante y finalmente produce una sola predicción tomando en cuenta la información relevante en su memoria, a esta se le llamará etapa de memoria artificial. Los 2 mejores resultados utilizan solo una capa LSTM de 512 unidades ocultas (neuronas).


Commented [GU4]: Actualizar cuando ya se tengan los resultados definitivos.

La diferencia radica en el tipo de modelo convolucional usado:

- a) **Densenet121:** Se tuvieron resultados exitosos pero el modelo Densenet121 posee un alto costo computacional implicando que cada experimento tomara alrededor de 36 horas de procesamiento, se desechó a favor de un modelo posiblemente menos exacto pero que permite experimentar más rápida y ágilmente.

- b) **Vgg19**: El modelo más simple y con menor número de parámetros que Densenet121 y por lo tanto menor costo computacional, este permitió experimentar con más opciones en menos tiempo (un promedio de 2 horas por experimento) obteniendo resultados a favor de las hipótesis.

Figura No. 5 Arquitectura modelo **Vgg19**



Fuente: Clifford K. Yang 2019.

Commented [LJ5]: Cambie esto si se usa otro, solo lo camian y me dicen


Para todos los casos se usó como función de activación en la capa de salida del modelo recurrente la función sigmoïdal o logística definida como:

$$y = \frac{1}{(1 + e^{-x})}$$

Esta función tiene como objetivo generar un número entre 0 y 1 que se interpreta como la probabilidad de que en la secuencia de imágenes de cierto paciente esté presente alguna afección.

A continuación, se ejemplifica el modelo combinado propuesto para un paciente ficticio de ejemplo, para este caso el paciente posee 3 imágenes tomográficas, cada imagen es analizada por el modelo de visión artificial vgg19 y se almacena información relevante en el modelo de memoria artificial LSTM para luego emitir un único diagnóstico.

Figura No. 6 Arquitectura del modelo combinado vgg19-LSTM



Fuente: Realización propia 2019.

3.8.5 Proceso de entrenamiento/aprendizaje

El proceso de entrenamiento y aprendizaje en un algoritmo de aprendizaje de maquina consiste en la optimización de una función objetivo definida de acuerdo con el tipo de problema y modelo.

Para este proyecto, considerando que el modelo es probabilístico y estima una distribución de probabilidad, se utilizó la correspondiente función de costo conocida como “entropía cruzada” que estima cuanto difieren 2 distribuciones de probabilidad:

- La distribución real: diagnósticos reales provistos por un médico.

- La distribución aproximada: diagnósticos realizados por el modelo de inteligencia artificial.

Debido al desbalance en proporción de positivos vs negativos en la muestra de imágenes (mínimo porcentaje de diagnósticos positivos) se utilizó una variación de la entropía cruzada conocida como “entropía cruzada ponderada” que da más importancia a la categoría menos predominante, en este caso diagnósticos positivos, por cada tipo de diagnóstico se calculó el factor de ponderación de positivos con la expresión:

$$P_c = \frac{total_negativos}{total_positivos}$$

La entropía cruzada ponderada se define como:

$$L_s = -\beta Y^* \log \hat{Y} - (1 - Y^*) \log(1 - \hat{Y})$$

El objetivo de optimización por lo tanto es minimizar la entropía cruzada entre las 2 distribuciones mencionadas a través de un optimizador iterativo basado en calculo multivariable conocido como “gradiente en descenso”. Específicamente se utilizó su derivado conocido como Adam (del inglés Adaptive Moment Optimization) que acelera la optimización utilizando un modelo de momento lineal y restringiendo oscilaciones en dirección vertical del gradiente de la función objetivo.

En aprendizaje de máquina la optimización se realiza en una de 3 posibles formas:

1. Por lote: cada iteración de la optimización utiliza toda la muestra de entrenamiento (todos los pacientes)

2. Estocástico: cada iteración de la optimización utiliza una observación en la muestra (un paciente a la vez)
3. Por mini lotes: cada iteración de la optimización utiliza una submuestra de tamaño “m” del total de la muestra (un subconjunto de “m” pacientes)

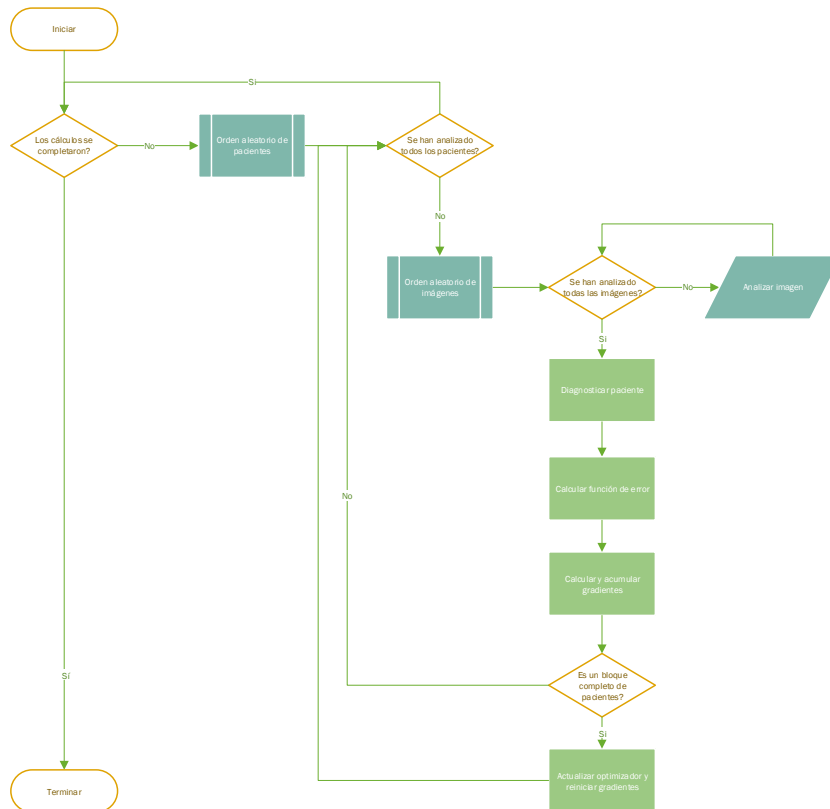
Debido a la naturaleza del problema, contar con un número desconocido y variable de imágenes por paciente, no es posible aplicar los tipos 1 y 3 ya que estos esperan estructuras de datos uniformes, pero el tipo 2 es conocido por provocar una varianza alta en el cálculo de gradientes (Johnson & Zhang, 2013, p. 9) para reducir esto se diseñó un flujo de entrenamiento que combina los tipos 2 y 3.

1. Se alimenta y se calcula la función de optimización un paciente a la vez (tipo 2) pero los gradientes son acumulados contrario a ser usados inmediatamente.
2. Se aplica una iteración de optimización con los gradientes acumulados cada 16 pacientes (tipo 3).

Adicional a esto se aplicó en el entrenamiento un ordenamiento aleatorio de las imágenes de cada paciente para romper la correlación entre el orden temporal de imágenes con el diagnóstico correspondiente, evitando así que el modelo secuencial memorice (almacene en su memoria) un orden específico de patrones visuales por diagnóstico.

Commented [GU6]: Diagrama de flujo a alto nivel

Figura No. 7 Diagrama de flujo del aprendizaje



Fuente: Realización propia 2019.

3.8.6 Hiper parámetros y configuraciones

En todos los experimentos se utilizó como método de minimización de la función de costo el optimizador Adam (Diederik Kingma, 2015) y experimentamos con múltiples valores del hiper parámetro conocido como tasa de aprendizaje encargado de controlar el tamaño o magnitud de las actualizaciones durante la optimización, se encontró que una combinación efectiva fue:

- Iniciar la tasa de aprendizaje en 0.0003
- Aplicar decaimiento de la tasa de aprendizaje hasta un mínimo de 0.00001

Commented [L7]: Evaluar opción de notación científica

Commented [L8]: Evaluar opción de notación científica

Como fue descrito en la sección de arquitectura se usaron capas de 512 neuronas tanto para la capa oculta del modelo recurrente, como para la capa de salida del del modelo convolucional.

Para este proyecto se utilizó optimización basada en gradiente en descenso estocástico lo cual significa que se presentó al modelo la información de un paciente a la vez, esto debido a que el número de imágenes por paciente es variable, hacerlo de esta forma tiene como consecuencia que el proceso sea más lento y no aproveche del todo el paralelismo del hardware usado por lo cual cada experimento tardaba aproximadamente un mínimo de un día en entrenamiento.

3.8.7 Técnicas y métodos del marco teórico de inteligencia artificial


El marco teórico de inteligencia artificial provee algunas técnicas y métodos que han resultado útiles en el pasado, en este proyecto se experimentó con 2:

Aprendizaje por transferencia a través de congelar capas ocultas: se utilizó un modelo Vgg19 previamente entrenado en otra tarea T y se congelaron sus primeras capas de manera que no fluyera gradiente a través de ellas y estas no sean modificadas durante el entrenamiento, el efecto esperado es que las características y patrones que esta capa detecta aprendidas en la tarea T sean transferidas y aprovechadas en los experimentos para acelerar el proceso.

- Síntesis artificial y aumentado de datos: técnica que consiste en obtener nuevas imágenes a partir de aplicar alteraciones menores en las imágenes originales (por ejemplo, rotación, cambio de ubicación, redimensionado) con el objetivo de simular la variabilidad y aleatoriedad en la captura de datos inherente de la vida real, para el modelo tiene el efecto de ayudarlo a “ver” más posibles casos y por lo tanto se espera ayude a mejorar su exactitud y capacidad de generalización. En este proyecto se experimentó con rotaciones y redimensionado aleatorio.

Commented [L9]:

Figura No. 8 Comparación de tomografías originales vs por síntesis artificial



Fuente: Base de Datos Tomografías Cerebrales propia 2019.

3.8.8 Tamaño y distribución de la muestra de imágenes

El acceso y disponibilidad de imágenes fue: por etapas e incremental a lo largo del diseño y la experimentación, por lo tanto, se usaron distintas muestras para distintos experimentos conforme se tuvo acceso a ellas. Para todos los casos se mantuvo la misma distribución. El porcentaje de pacientes con diagnóstico positivo es mucho menor al porcentaje de pacientes con diagnóstico negativo.

A continuación, se puede ver por cada afección el porcentaje de pacientes con diagnóstico positivo tanto en la muestra usada para entrenamiento, como en la muestra usada para validación y selección.

Tabla No. II Proporción de positivos muestra para entrenamiento

ENFERMEDAD	MEDIA
Hemorragia	0.283048
Isquemia	0.111975
Fractura	0.071540
Masa	0.018663
Edema	0.153966

Fuente: Realización propia 2019

Tabla No. III Proporción de positivos muestra para validación

ENFERMEDAD	MEDIA
Hemorragia	0.283048
Isquemia	0.111975
Fractura	0.071540
Masa	0.018663
Edema	0.153966

Fuente: Realización propia 2019

Esto tiene como resultado que el modelo aprenda de manera sesgada a generar diagnóstico negativo en la mayoría de los casos. Para combatir esto se utilizó como función de costo (objetivo de optimización) a la función conocida como, entropía cruzada ponderada variación de la conocida entropía cruzada esta función se describe en la sección 4.10.12

De los 5 males que se buscó diagnosticar, “masa” nunca fue aprendido correctamente por el modelo y siempre tuvo punteo de 0 en la métrica f1 usada como prioridad en la evaluación.

3.9 Procesamiento y análisis de datos

Los modelos, como sujetos de estudio, el procesamiento y análisis de resultados consiste en capturar para cada experimento su configuración como: modelo matemático o modelos de inteligencia artificial usados, características y configuración de cada modelo en los experimentos, resultados como la exactitud que cada experimento logró, y el análisis. A partir de ello, qué tipos o configuraciones producen mejores resultados y apoyan los experimentos tanto como las hipótesis planteadas. Los datos cuantitativos capturados para cada experimento incluyen diversas métricas. Todas las métricas se encuentran en pareja (de entrenamiento y de validación y prueba) a excepción del error a través de la entropía cruzada (solo de entrenamiento) que es el objetivo de optimización del entrenamiento, por lo tanto, para cada métrica se tiene:

- De entrenamiento: resultado de la comparación entre diagnósticos reales (provistos por el médico) y diagnósticos obtenidos por la inteligencia artificial y que fueron utilizados para entrenarla.
- De prueba y validación: resultado de la comparación entre diagnósticos reales (provistos por el médico) y diagnósticos obtenidos por la inteligencia artificial y que no fueron utilizados para entrenarla por lo cual nunca los ha visto y son un estimador no sesgado de funcionamiento con futuros pacientes.

Tabla No. IV Formulas

MÉTRICA	DESCRIPCIÓN	CALCULO
Error de entrenamiento	Entropía cruzada entre la distribución de probabilidad de diagnósticos médicos vs diagnósticos del modelo. Se busca tener un valor bajo	$specificity = \frac{TN}{TN + FP}$
Exactitud	Porcentaje de diagnósticos acertados por la inteligencia artificial al comparar contra diagnósticos de un médico.	$accuracy = \frac{TP + TN}{TP + FN + TN + FP}$
Precisión	Porcentaje de pacientes diagnosticados positivo por la inteligencia artificial que si son positivos según diagnóstico médico.	$precision = \frac{TP}{TP + FP}$
Sensibilidad	Del total de pacientes con diagnostico positivo real cual es el porcentaje diagnosticado como tal por la inteligencia artificial.	$recall = \frac{TP}{TP + FN}$
Métrica f1	Media armónica precisión y sensibilidad con el objetivo de tener una sola métrica de evaluación.	$F1 = \frac{2 \times precision \times recall}{precision + recall}$

Fuente: Realización propia 2019.

3.10 Límites de la investigación

3.10.1 Obstáculos (riesgos y dificultades)

El mayor reto fue la escasez de imagen de tomografías axiales computarizadas disponibles para uso de investigación científica. Las instituciones privadas y públicas carecen de una cultura de comunidad científica en el país, por lo tanto, el acceso a esta información muchas veces es complicado. Esto se debe a que estos datos no están disponibles de manera gratuita y publica, sino que también existen procesos burocráticos que limitan a un equipo pequeño de investigadores para poder obtenerlos. En resumen: la inexistencia de una base de datos de acceso público de este tipo información dificulta la labor de investigación.

Otra de las limitaciones es debido a las actividades laborales de los miembros del grupo, la inversión de tiempo no es la misma si se compara con personal de tiempo completo en labores de investigación, por lo que la disponibilidad se convierte en una de las mayores dificultades para obtener los resultados esperados, comparándolo con un equipo con mayor disponibilidad de tiempo.

3.11 Aspectos éticos de la investigación

3.11.1 Principios éticos generales

3.11.1.1 Beneficencia y no maleficencia

Las imágenes fueron obtenidas a manera de datos anonimizados, es decir que los investigadores son incapaces de individualizar a la persona a la que se le realizó la tomografía. Eso nos asegura que el proceso es completamente de observación y experimentación (con las imágenes directamente), ya que en ningún momento se tiene ninguna interacción directa o indirecta con el paciente, que pueda incomodarlo o poner en riesgo su derecho de privacidad.

Estos datos son exclusivos para esta investigación, y en ningún momento será compartida con terceros que puedan poner en riesgo la privacidad de los pacientes cuyos resultados fueron utilizados.

Para los propósitos de esta investigación, nunca se realiza una recolección de datos personales de los pacientes, ya que estos son irrelevantes en innecesarios para su propósito, ya que todas las imágenes son completamente anónimas para los investigadores.

3.11.1.2 Autonomía

En la investigación realizada utilizo una muestra que se hizo disponible mediante imágenes de tomografías y su respectivo diagnóstico, sin ningún tipo de información del paciente al que se le realizaron. Estos datos fueron proporcionados de manera confidencial por la entidad participante, explicando cuál sería su uso y también firmando un compromiso de confidencialidad. Además, se asegura de que las imágenes no serán utilizadas con fines comerciales.

Estas imágenes solamente están disponibles para los miembros del equipo de investigación, y serán utilizados exclusivamente para esta. No existe ningún de marca o registro criptográfico que permita a los investigadores el identificar a un paciente.

3.11.1.3 Respeto por las personas

Como se mencionó, estos datos fueron entregados de manera confidencial. Cualquier rastro de información personal fue eliminado previo a compartirlo con el equipo de investigación. No existió ningún tipo de abuso a la privacidad de los pacientes.

Como se mencionó, estos datos fueron entregados de manera confidencial. Cualquier rastro de información personal fue eliminado previo a compartirlo con el equipo de investigación. No existió ningún tipo de abuso a la privacidad de los pacientes.

3.12 Categorías de riesgos

Debido a que los propósitos de experimentación basada en la observación y entrenamiento de un agente inteligente, usando datos completamente anonimizados, no existe un riesgo tangible en la investigación, por lo cual se puede decir que se clasifica en la Categoría I.

3.12.1 Categoría I (sin riesgo)

No existe ninguna interacción directa o indirecta con los pacientes, ya que ni siquiera se sabe quiénes son, ya que todos los datos son completamente anónimos. No existe ninguna amenaza para la privacidad de estos, por lo que, al no existir ningún riesgo, no hay plan de acción para este.

4 ESTUDIO TÉCNICO

El presente capítulo ofrece una descripción detallada sobre el funcionamiento y operatividad del área en estudio y lo relacionado con ello, así mismo la situación en que se encuentran las áreas de inteligencia artificial, las cuales son motivo del presente informe final.

4.1 Descripción del área de influencia

El estudio tuvo impacto directo en el análisis e interpretación de imágenes diagnósticas (tomografías cerebrales) y facilitará a los médicos la toma de decisiones especialmente en las áreas de urgencia de la ciudad de Guatemala.

Este modelo de inteligencia artificial también podrá ser aplicado en campos no solo de la medicina sino en cualquiera que esté relacionado con análisis e interpretación de imágenes.

4.2 Misión del modelo

Facilitar procesos y toma de decisiones en el campo de la medicina (imágenes diagnósticas) y en campos que requieran análisis de imágenes, por medio de un modelo matemático de inteligencia artificial más exacto.


4.3 Visión del modelo

Implementar un modelo matemático de inteligencia artificial más exacto para el análisis de imágenes.

4.4 Organización del talento humano para la creación del modelo

Se Ingenieros en sistemas capacitados en el desarrollo e implementación de inteligencia artificial que facilite el análisis e interpretación de imágenes .

Figura No. 9 Organigrama del talento humano para la creación del modelo



Fuente: Realización propia 2019.

4.5 Área de atención del modelo

Cualquier área que requiera análisis e interpretación de imágenes para pacientes de instituciones sanitarias en Guatemala.

4.6 Recursos físicos y tecnológicos del modelo

Actualmente no existe una inteligencia artificial que esté disponible y los recursos que se necesitan para desarrollarla son los siguientes:

4.6.1 Recursos físicos

- Sillas y escritorios
- Lapiceros y lápices
- Cuadernos
- Imágenes
- Energía eléctrica

4.6.2 Recursos tecnológicos

- Computadoras
- Memorias externas
- Software

4.7 Estudio de mercado

4.7.1 Capacidad

El modelo no está disponible en el mercado actualmente, al desarrollarlo pude ponerse a disposición de público que lo requiera, media vez pueda pagarlo.

4.7.2 Demanda

El modelo podrá ser utilizado por las personas e instituciones que trabajen en análisis e interpretación de imágenes.

4.7.3 Infraestructura

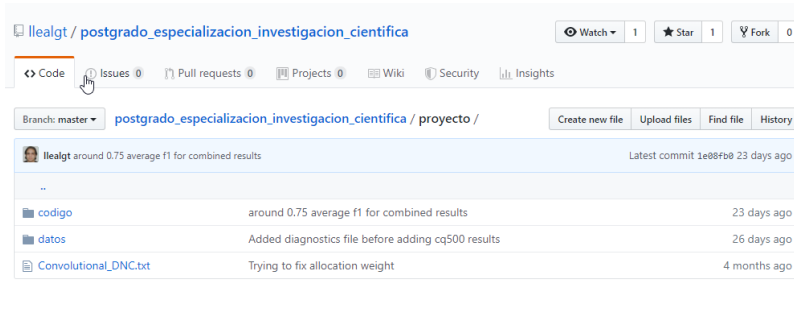
Digital.

5 PROPUESTA DE SOLUCIÓN

La actual propuesta se encuentra en un repositorio remoto de Github que pertenece a uno de los miembros del equipo de investigación. El modelo este contenido en archivos que son notebooks de Jupyter usando el lenguaje de programación Python, un archivo maestro de configuración y el conjunto de imágenes utilizado como fuente de datos para el entrenamiento del modelo. El repositorio mencionado se describe a continuación y puede ser encontrado en la siguiente dirección web:

https://github.com/llealgt/postgrado_especializacion_investigacion_cientifica/tree/master/proyecto

Figura No. 10 Vista del repositorio en sitio web



Fuente: Realización propia 2019.

5.1 Código

En este directorio dentro del repositorio se encuentran los notebooks de Jupyter, con el código Python, que fueron utilizados para el desarrollo del modelo. Existe un notebook para cada uno de los resultados esperados.

5.1.1 Prototipos edemas

Este notebook contiene las funciones y métodos necesarios para el entrenamiento del modelo, en los casos cuyo diagnóstico es edemas, guardando los resultados en un archivo de Excel. Dichas funciones analizan las imágenes disponibles. Contiene además la configuración para dicho código, como la cantidad de imágenes que procesara por lote y las ubicaciones de las fuentes y destinos de datos.

5.1.2 Prototipos fractura

Funciona de la misma manera que el prototipo para edemas, pero en este caso es para los diagnósticos de fractura craneal.

5.1.3 Prototipos hemorragia

Funciona de la misma manera que el prototipo para edemas, pero en este caso es para los diagnósticos de hemorragia cerebral.

5.1.4 Prototipos isquemia

Funciona de la misma manera que el prototipo para edemas, pero en este caso es para los diagnósticos de isquemia.

5.1.5 Prototipos masa

Funciona de la misma manera que el prototipo para edemas, pero en este caso es para los diagnósticos de masas craneales atípicas.

5.1.6 Prototipos todos

Funciona de la misma manera que el prototipo para edemas, pero en este caso incluye todos los posibles diagnósticos descritos antes.

5.1.7 Prototipos

Este notebook contiene las funciones y métodos necesarios para la experimentación con el modelo, utilizando las bibliotecas de Tensor Flow. Uno de ellos utiliza la red neuronal profunda alimentada de una imagen a la vez en orden aleatorio con pacientes también en orden aleatorio

Figura No. 11 Notebook con código de Python

```
Notas y recordatorios
• Por la forma en que se prepararon los datos renombre temporalmente el paciente 120 a paciente 6(para mantener la
continuidad de la muestra) y lo puse también como 6 en los diagnosticos.
• Similar al punto anterior pero con el paciente 121 y el 7
• Similar pero con el paciente 8

In [3]: # for fast experimentation on slow computer Limit the size of the sample
MAX_PATIENTS = 800
MINI_BATCH_SIZE = 32 #currently not used for mini batch split but for deciding when to do backward and zero
grad

In [4]: DATA_DIRECTORY = "../datos/TOMOGRAFIAS/"
VALIDATION_FRACTION = 0.10

In [5]: diagnosticos = pd.read_excel(DATA_DIRECTORY+"RESUMEN TAC CEREBRALES.xlsx")
nombres_diagnosticos = diagnosticos.columns[1:-1]

In [6]: diagnosticos.count()

Out[6]: paciente      1142
```

Fuente: Realización propia 2019.

5.2 Datos

En este directorio se encuentran las imágenes de tomografías craneales que serán utilizadas para entrenar el modelo cuyo código se encuentra en el repositorio. Estas imágenes se encuentran a modo de agruparse por paciente con su respectivo diagnóstico.

5.2.1 Resumen TAC Cerebrales

Dentro de este directorio de datos también se encuentra esta hoja de cálculo que contiene un detalle de los diagnósticos identificados por el modelo. Este archivo se utiliza para validar los resultados.

5.3 Archivo de configuración “Convolutional_DNC.txt”

Este archivo de texto plano contiene la configuración de la red neural convolucional que se utiliza como parte del modelo. Contiene la configuración y los hiper parámetros necesarios para adecuarla a las necesidades de este, como por ejemplo el tamaño de la memoria reservada, el tamaño de las “palabras” de datos, etc.


6 ANÁLISIS DE RESULTADOS

A lo largo del proyecto se realizaron múltiples experimentos con diferentes tamaños de muestra y condiciones, a continuación, se describen los experimentos más relevantes, sus resultados y conclusiones.

6.1 Experimento 1

- Tamaño de muestra de entrenamiento 508 pacientes (no se poseía la muestra completa a esta fecha)
- No se usó muestra de validación y pruebas.
- Modelo convolucional: densenet121
- 300 epochs de entrenamiento, aproximadamente 36 horas de procesamiento.
- Un único modelo para todos los diagnósticos (vector de diagnósticos).

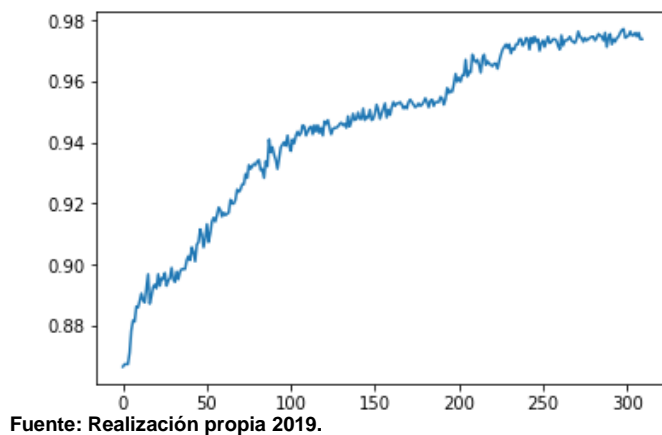
Figura No. 12 Función de costo/error de entrenamiento



Fuente: Realización propia 2019.

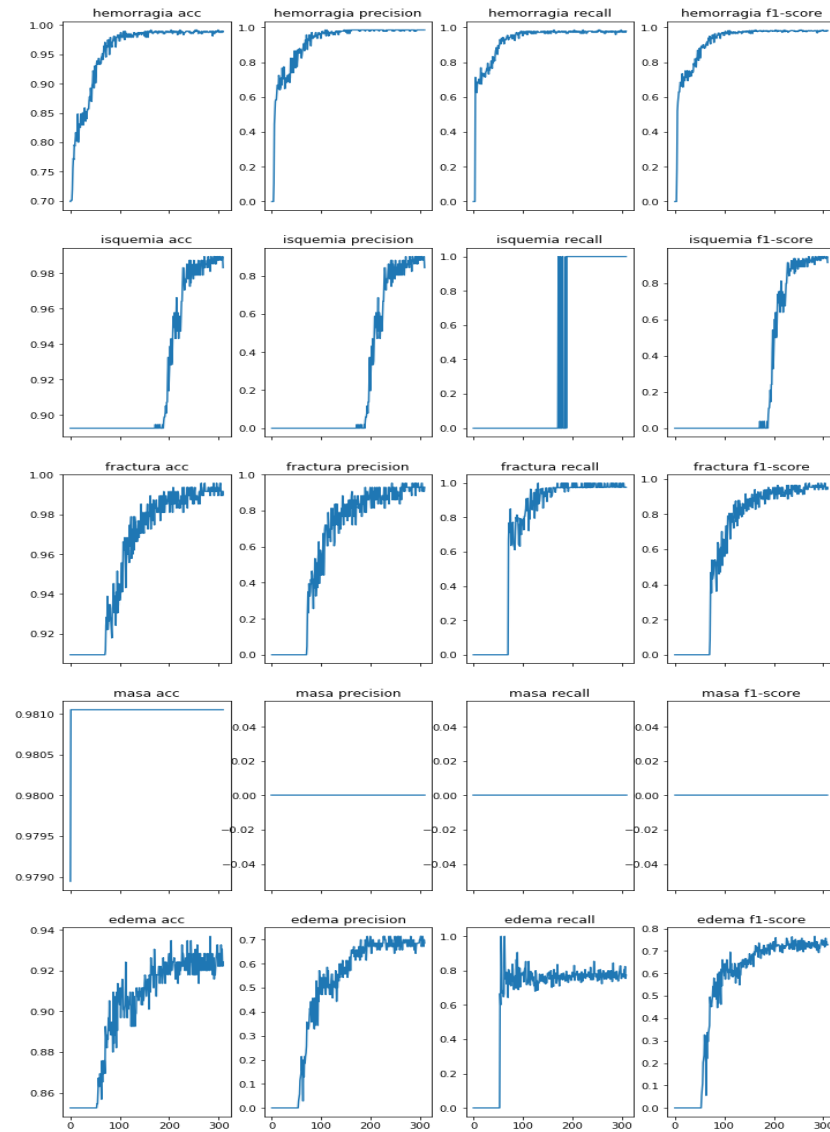
Análisis: el error calculado con la entropía cruzada disminuye conforme avanza el entrenamiento, esto mide que tanto difieren los diagnósticos de la inteligencia artificial contra los del médico de manera probabilística, la disminución es positiva.

Figura No. 13 Exactitud promedio de entrenamiento



Análisis: la exactitud promedio (promediando la exactitud de los 5 diagnósticos) incrementa durante el entrenamiento, esta mide el porcentaje de aciertos en el diagnóstico de la inteligencia artificial sobre la muestra de pacientes con la cual está siendo entrenada, el incremento es positivo.

Figura No. 14 Métricas de evaluación



Fuente: Realización propia 2019.

Análisis: a excepción del diagnóstico de masa, todos los diagnósticos incrementaron sus métricas de evaluación (medidas sobre la muestra de pacientes de entrenamiento) conforme el aprendizaje avanza, el incremento es positivo y el valor de 0 de masa es no deseado, debido al porcentaje extremadamente bajo de pacientes con este diagnóstico.

Los resultados experimentales concuerdan con las hipótesis planteadas, las métricas de error disminuyen conforme avanza el entrenamiento y las métricas de evaluación muestran un incremento en todos los diagnósticos (llegando incluso a métricas casi perfectas para hemorragia) a excepción del diagnóstico de masa que aunque tiene una exactitud de casi el 99% tiene 0% en el resto de métricas, esto debido a que la muestra tiene muy pocos pacientes con diagnóstico positivo en masa, por lo cual la inteligencia artificial aprende a diagnosticar de manera sesgada la ausencia de masa para todos los casos.

En conclusión, los resultados son positivos y concuerdan con las hipótesis planteadas, pero no son determinantes por 2 razones:

1. La muestra usada es muy pequeña (512 pacientes)
2. No se usó muestra de validación y pruebas

Bajo estas condiciones es probable que la inteligencia artificial este memorizando las imágenes y diagnósticos con las que fue entrenada lo cual se traduce estadísticamente a un sobreajuste del modelo a la muestra de entrenamiento.

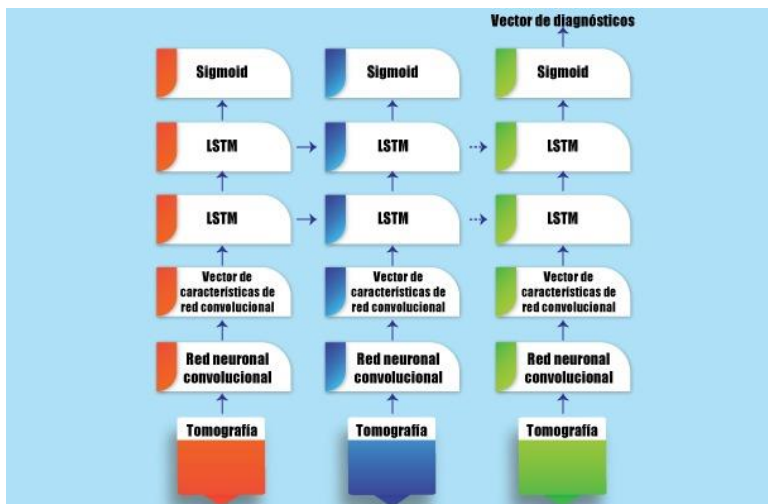
6.2 Experimento 2

Adicional al modelo se experimentó con modelos específicos (un único diagnóstico) describiendo, a continuación, el mejor para el caso de hemorragia.

- Tamaño de muestra de entrenamiento :643 pacientes
- 23 imágenes en promedio por paciente
- A esto se agregaron 10 pacientes positivos en hemorragia de la base de datos CQ500 con el objetivo de mejorar la generalización del modelo.
- Tamaño de muestra de validación y prueba: 72 pacientes
- Modelo convolucional: Vgg19
- Modelo secuencial: 2 capas LSTM con 512 neuronas cada una
- 120 epochs de entrenamiento, aproximadamente 6 horas de procesamiento.
- Diagnóstico único: hemorragia


Commented [GU10]: Donde ponemos la referencia al paper?

Figura No. 15 Diagrama de arquitectura (alto nivel) del modelo combinado



Fuente: Realización propia 2019.


Figura No. 16 Función de costo/error de entrenamiento



Fuente: Realización propia 2019.

Análisis: el error calculado con la entropía cruzada ponderada disminuye conforme avanza el entrenamiento, esto mide que tanto difieren los diagnósticos de la inteligencia artificial contra los del médico de manera probabilística, la disminución es positiva.


Figura No. 17 Exactitud de entrenamiento



Fuente: Realización propia 2019.

Análisis: la exactitud medida como el porcentaje de aciertos en diagnóstico de hemorragia sobre la muestra de pacientes de entrenamiento alcanza un valor superior al 95% lo cual se interpreta como que la inteligencia artificial diagnóstica correctamente sobre la mayoría de los pacientes con los cuales fue entrenada.

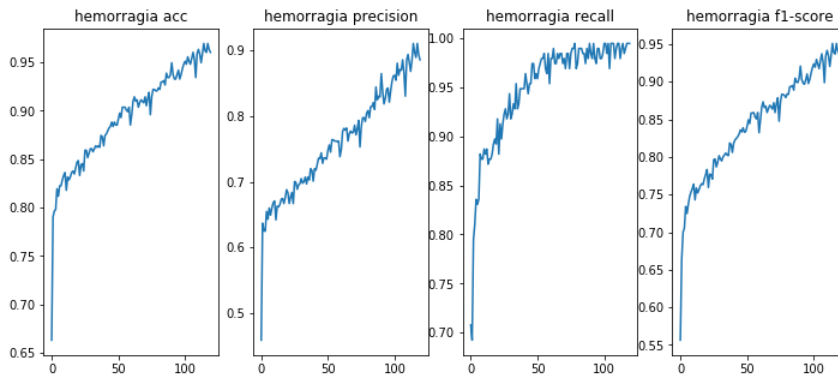
Figura No. 18 Exactitud de validación



Fuente: Realización propia 2019.

Análisis: la exactitud medida como el porcentaje de aciertos en diagnóstico de hemorragia sobre la muestra de pacientes de validación alcanza un valor del 85% lo cual se interpreta como que la inteligencia artificial diagnóstica de manera correcta a aproximadamente el 85% de pacientes que nunca había visto durante su entrenamiento, esto es una estimación de su exactitud en diagnósticos de nuevos pacientes.

Figura No. 19 Métricas de evaluación de entrenamiento

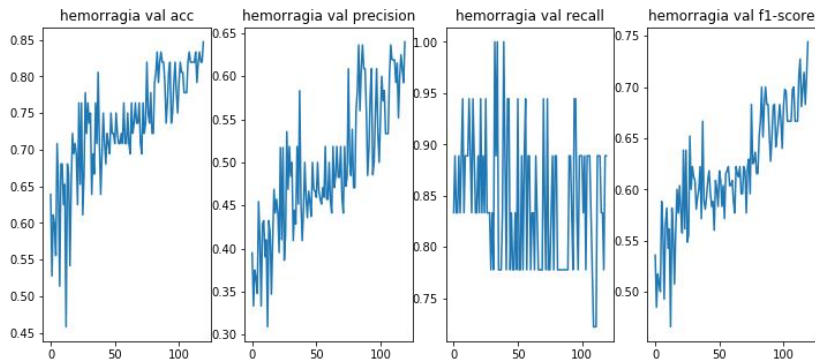


Fuente: Realización propia 2019.

Análisis: las métricas de evaluación de entrenamiento miden además de la exactitud general otros aspectos importantes cómo:

- **Precisión:** de los pacientes diagnosticados como positivos por el modelo, que porcentaje lo estaba según el médico, el valor supera el 90%
- **Sensibilidad:** del total de pacientes positivos según el diagnóstico médico, cual fue diagnosticado como tal según la inteligencia artificial, el valor alcanza el 98%

Figura No. 20 Métricas de evaluación de validación



Fuente: Realización propia 2019.

Análisis: los resultados experimentales muestran que el error de entrenamiento disminuye y la exactitud, tanto de entrenamiento como de validación, incrementan durante el entrenamiento, lo cual es consistente con las hipótesis planteadas. Por esto, podemos concluir lo siguiente:

- Exactitud de entrenamiento de 95%: significa que la inteligencia artificial es capaz de diagnosticar hemorragia de manera acertada en aproximadamente el 95% de la muestra de pacientes con la cual fue entrenada
- Exactitud de validación de 85%: significa que la inteligencia artificial es capaz de diagnosticar hemorragia de manera acertada aproximadamente en el 85% de pacientes de la muestra de validación (pacientes no vistos por el modelo durante su entrenamiento).
- Se puede observar, aunque tanto las métricas de entrenamiento como las de validación tienden a incrementar, la diferencia entre estos 2 tipos es alta lo cual sugiere un sobreajuste estadístico posiblemente debido al pequeño tamaño de la muestra de pacientes, esto es una posible mejora a futuro del proyecto.

6.3 Resumen de resultados

Además de los experimentos detallados, se recopiló una tabla resumen donde por cada tipo de diagnóstico hay 2 métricas:


- Porcentaje diagnósticos: que porcentaje de la muestra presenta un diagnóstico positivo.
- Métrica de evaluación f1 calculada en pacientes de validación. Se eligió la métrica f1 ya que es una media armónica de precisión y sensibilidad, métricas adecuadas para datos desbalanceados (diagnósticos en distinta proporción).

Tabla No. V Resumen de resultados

ENFERMEDAD	PORCENTAJE DE DIAGNÓSTICOS	MÉTRICA F1 DE VALIDACIÓN
Hemorragia	0.283048	0.750000
Isquemia	0.108865	0.450000
Fractura	0.073095	0.636000
Masa	0.017107	0.666000
Edema	0.144635	0.487700

Fuente: Realización propia 2019.

Figura No. 21 Histograma de Resultados



Fuente: Realización propia 2019.

Análisis: de este resumen se puede concluir que hemorragia es el diagnóstico con mejores resultados, lo cual coincide con ser el diagnóstico con un porcentaje de pacientes positivos más alto en la muestra, esto complementa los hallazgos de posible sobreajuste estadístico descrito en los experimentos y se concluye que, aunque se demuestra que nuestras hipótesis son verdaderas existe la posibilidad de mejorar la calidad de los diagnósticos a través de usar una muestra mayor de pacientes.

7 COSTOS APROXIMADOS Y ANÁLISIS FINANCIERO

En esta sección se explican los detalles de los costos aproximados del proyecto, así como un análisis financiero. Adicionalmente se incluye una propuesta de mejora para los costos que permita mejorar el proceso investigativo, finalmente se define un análisis de costo beneficio y una propuesta económica para el proyecto.

7.1 Costo de estudio

Para la realización, fue necesario establecer los recursos humanos, físicos y materiales necesarios para su realización. En el caso del primero se muestra individualmente para dar una idea de las horas necesarias de cada especialista.

Tabla No. VI Recursos humanos

CANTIDAD	TIEMPO	DESCRIPCIÓN	PRECIO UNITARIO	TOTAL, PARCIAL
2	200 horas	Ingenieros en sistemas para realizar trabajo de campo (creación de modelos, entrenamiento, testeo).	Q 200.00	Q 40,000.00
1	20 horas	Médico para clasificación de imágenes tomográficas.	Q 150.00	Q 3,000.00
1	400 horas	Médico radiólogo para interpretación de imágenes.	Q 150.00	Q 60,000.00
6	90 horas	Investigadores	Q 150.00	Q 81,000.00
1	8 semanas	Asesor	Q 2,000.00	Q 2,000.00
Total				Q 186,000.00

Fuente: Realización propia 2019.

En cuanto a los servicios de comunicación utilizados, se entienden por los servicios de llamadas telefónicas y de internet móvil o residencial de cada uno. Para los imprevistos se definió una cantidad fija, no basada en un porcentaje porcentual. Las fotografías de las tomografías craneales fueron donadas y anonimizadas para proteger la identidad de los pacientes. El GPU es necesario para realizar los cálculos del modelo, que requieren hardware especializado con un alto grado de paralelismo, para que puedan ejecutar millones de operaciones matemáticas por segundo.

Tabla No. VII Recursos físicos, tecnológicos y materiales

CANTIDAD	MATERIAL	PRECIO UNITARIO	PARCIAL
6	Computadoras	Q 9000.00	Q 54,000.00
1	Disco duro externo	Q 500.00	Q 500.00
1	GPU	Q 7,200.00	Q 7,200.00
3	Energía eléctrica/mes	Q 300.00	Q 900.00
750	Impresiones	Q 0.25	Q 187.50
6	Servicios de comunicación	Q200	Q 1,200.00
15,300	Fotografías de TAC	Q 0.00	Q 0.00
	Gastos Imprevistos		Q 5,000.00
TOTAL			Q 68,987.50

Fuente: Realización propia 2019.

7.2 Presupuesto de mejora

Como parte de las mejoras que se pueden aplicar al trabajo propuesto de investigación, con un presupuesto más alto del mínimo, se podrían utilizar al menos un GPU adicional para disminuir el tiempo de procesamiento necesario. La mayor limitante que actualmente se tiene es la cantidad de recursos de este tipo, ya que, al ser una tarea de alto paralelismo, el hecho de tener un nuevo GPU para trabajar implica un incremento en la eficiencia de casi el doble del que se tiene actualmente.

En la tabla se detallan los costos para ser aplicados durante la misma ventana de tiempo que actualmente se fijó para trabajar. En cuanto al recurso humano se determinó que con lo que contamos actualmente es suficiente y no implicaría una mejora importante el incrementarlo. Fuera del costo del GPU, el otro costo importante es el consumo de energía eléctrica de estos componentes de computadoras, pero materialmente, no se necesita hacer otro gasto ya que el equipo actual es modular y permite incrementar su capacidad.

Tabla No. VIII Recursos físicos, tecnológicos y materiales propuestos

CANTIDAD	CONCEPTO	PRECIO UNITARIO	TOTAL, PARCIAL
1	GPU	Q 7,200.00	Q 7,200.00
3	Energía eléctrica/mes	Q 300.00	Q 900.00
TOTAL			Q 8,100.00

Fuente: Realización propia 2019.

7.3 Análisis financiero

En cuanto a la inversión inicial, solamente se ha considerado el material físico y tecnológico necesario para comenzar con la investigación y el desarrollo informático.

El precio del software se ha definido como la inversión del recurso humano de los desarrolladores de software y el apoyo de ambos médicos para la clasificación e interpretación de imágenes, siendo esta cantidad la suma de las horas de honorarios de cada uno de estos profesionales, ya que ambos se consideran como aportes directos al agente inteligente, unos como desarrolladores y los otro como parte del entrenamiento de este.

Se han definido como recursos humanos auxiliares al apoyo que estarán dando investigadores y el asesor a los profesionales informáticos y de la medicina, que no implican un gasto directo en el desarrollo del modelo.

Tabla No. IX Consideraciones de gastos de implementación

DESCRIPCIÓN	TOTAL
Inversión Inicial	Q 68,987.50
Precio estimado del software creado	Q 103,000.00
Recursos humanos auxiliares	Q 83,000.00
TOTAL	Q 254,987.50

Fuente: Realización propia 2019.

No existe actualmente un punto de referencia con el cual se pueda decir que esta inversión será una optimización, ya que lo que se busca es crear un precedente dentro del sistema de salud nacional. Por lo tanto, para esta comparación solo se utiliza el precio de la inversión inicial como punto de referencia, mientras que la relación de costo beneficio es considerada como algo que no aplica durante este momento de la investigación.

Tabla No. X Cálculo económico actual

DESCRIPCIÓN	TOTAL
Costo por morbilidad de un paciente anual	Q 178,000.00
Costo por mortalidad de un paciente anual	Q 76,00.00

Fuente: Realización propia 2019.

7.4 Análisis financiero de costo-beneficio

Inversión Inicial para desarrollo de modelo: Q 254,987.50

Costo anual por morbilidad de un paciente: Q178,000.00

(costos anuales relacionados con complicaciones en la demora en el diagnóstico de un solo paciente)

Costo anual por mortalidad de un paciente: Q76,000.00

(Costo anual por la muerte de un paciente con demora en el diagnóstico)

La siguiente tabla contiene los costos relacionados con las complicaciones sufridas por un solo paciente en el que ha habido demora en el diagnóstico de imágenes tomográficas.

Tabla No. XI Costos que representa no tener el modelo

Costo por morbilidad por paciente anual	
(medicamentos permanentes, fisioterapia, complicaciones)	Q178,00.00
Costo por mortalidad por paciente anual	
(gastos funerarios y sostenimiento de familiar)	Q 76,000.00

Fuente: Realización propia 2019.

La siguiente tabla describe el costo beneficio de la implementación de un modelo de inteligencia artificial

Tabla No. XII Cálculo económico actual y relación costo-beneficio

Costo anual por la morbimortalidad de un paciente	Q 254,000.00
Costo inicial para el desarrollo del modelo	Q 254,987.50
Relación Costo / beneficio	$254,987.50 / 254,000 = 1.00$

Fuente: Realización propia 2019.

Con relación al análisis realizado se concluye que los gastos que ocasionaría la morbimortalidad de un solo paciente en el que hubiese habido retraso en el diagnóstico de imágenes tomográficas cerebrales en un año podría cubrir el costo inicial del desarrollo de un modelo de inteligencia artificial que combine visión y memoria para la interpretación de imágenes tomográficas.

7.5 Propuesta económica de proyecto

- Que se contraten dos ingenieros en sistemas con conocimientos de inteligencia artificial por un periodo de 200 horas combinadas para el desarrollo del agente inteligente, por un periodo aproximado de tres meses.
- Contratar los servicios de un médico con conocimientos de radiológica para que clasifique el inventario de imágenes de tomografías craneales donado, para que estos puedan ser utilizados para el entrenamiento del agente inteligente.
- Es necesario también contar con un médico radiólogo por 400 horas para que este pueda validar los resultados del entrenamiento del agente inteligente.
- Es necesario el contar con al menos una computadora con un GPU relativamente moderno que soporte el uso de las herramientas de aprendizaje que se estarán utilizando. Es indispensable este requisito para cumplir con por lo menos las metas básicas.
- Diferentes gastos de insumos como papel, energía eléctrica, etc. Como todos los gastos que fueron previamente descritos, serán cubiertos por el equipo de investigación, incluyendo los honorarios profesionales.

CONCLUSIONES

1. Es posible combinar un modelo de visión artificial (modelo convolucional) con un modelo secuencial o de memoria artificial para lograr un diagnóstico muchos a uno (número variable y desconocido de imágenes a un único diagnóstico médico).
2. Se diseñó, describió y creó un modelo de inteligencia artificial (y un flujo de entrenamiento) que puede ser entrenado en una computadora casera y lograr una exactitud de aproximadamente 85% en el diagnóstico del mal predominante: hemorragia.
3. La muestra utilizada resultó ser pequeña y los resultados pueden ser mejorados con muestras mayores de pacientes (sus imágenes y diagnósticos).

RECOMENDACIONES

1. Recopilar una muestra más grande (imágenes y diagnósticos respectivos) y variada con el objetivo de mejorar la exactitud y métricas de evaluación de la inteligencia artificial.
2. Aplicar búsqueda sistemática de hiper parámetros.
3. Realizar el procedimiento de análisis del error para identificar si existe un patrón en los casos de diagnóstico no exitoso.
4. En caso de tener acceso a hardware con una mayor capacidad de procesamiento, experimentar con modelos más complejos.
5. Utilizar el modelo con otras aplicaciones, tanto dentro de la medicina como en otros campos en los que se requiera análisis de imágenes.

BIBLIOGRAFÍA

1. Alex, G., & Wayne, G. (2016). **Computación Híbrida usando una red neuronal con memoria externa dinámica**, “Hybrid computing using a neural network with dynamic external memory”. Nature, 21.
2. Arauz-Góngora, A., Coral-Casas, J., & Leyva-Rendón, A. (2005). **Isquemia cerebral transitoria**. Conceptos actuales. Arch Neurocién, 5.
3. Ballard, D., & Brown, C. (1982). **Visión de Computadoras**, “Computer Vision”. New York: Prentice Hall, Inc.
4. Bela Ajtai, J. C. (2016). **Neurología de Bradley en Práctica Clínica**, “Bradley's Neurology in Clinical Practice”, Seventh Edition. Miami, Florida: Elsevier Inc.
5. Esqueda-Liquidano, M. A. (2014). **Edema cerebral I: fisiopatología, manifestaciones clínicas, diagnóstico y monitoreo neurológico**. MedIntMex, 584-590.
6. Fauw, J. (2018). **Aprendizaje profundo aplicable clínicamente para el diagnóstico y referencia de enfermedades retinales**, “Clinically applicable deep learning for diagnosis and referral in retinal disease”. Nature Medicine, 24.
7. Goldman, L. M., & Schafer, A. I. (2019). **Medicina de Goldman-Cecil**, “Goldman-Cecil Medicine”, Twenty-Sixth Edition. New York: Elsevier, Inc.
8. He, K., Zhang, X., Ren, S., & Sun, J. (2015). **Aprendizaje profundo residual para reconocimiento de imágenes**, “Deep Residual Learning for Image Recognition”. Computer Vision Foundation, 770-778.
9. Hernández López, L. (2006). **Predicción y optimización de emisiones y consumo mediante redes neuronales en motores diésel**. Editorial Reverte.

10. Hochreiter, S., & Schmidhuber, J. (1997). **Memoria de Largo Corto Alcance, "LONG SHORT-TERM MEMORY"**. Institute of Bioinformatics - Johannes Kepler University Linz, 32.
11. Johnson, R., & Zhang, T. (2013). **Acelerando la caída de gradiente estocástica usando Procesamiento de información neural, "Accelerating Stochastic Gradient Descent using Neural Information Processing"** Systems Conference, 9.
12. K.M.A. Welch, L. R. (2017). **Primicia en enfermedades cerebrovasculares, segunda edición, "Primer on Cerebrovascular Diseases 2nd Edition"**. (M. Louis R. Caplan, Ed.) Boston: Academic Press.
13. Littleton, J. (s.f.). **Una historia de las ciencias radiológicas, "A History of the Radiological Sciences"**. American Roentgen Ray Society. Recuperado el 18 de 9 de 2019
14. Mitchell, T. (1997). **Aprendizaje automatizado, "Machine Learning"**. McGraw Hill. Recuperado el 18 de 9 de 2019
15. Panesar, A. (2019). **Aprendizaje automático e IA para cuidados médicos: Datos masivos para mejorar los resultados saludables, "Machine Learning and AI for Healthcare: Big Data for Improved Health Outcomes"**. Coventry, UK: Apress.
16. Parasuraman, R., & Riley, V. (1997). **Humanos y automatización: Uso, mal uso, desuso y abuso, "Humans and Automation: Use, Misuse, Disuse", Abuse**. Sage Journals, 230-253.
17. Prabhakar, H. (2017). **Esenciales de neuro anestesia, "Essentials of Neuroanesthesia"**. London: Mara Conner.
18. Stuart Russell, P. N. (2010). **Inteligencia artificial: Un enfoque moderno, "Artificial Intelligence A Modern Approach"**. San Francisco: Prentice Hall.
19. Topol, E. J. (2019). **Medicina de alto rendimiento: La convergencia de la inteligencia humana y artificial, "High-performance medicine: the convergence of human and artificial intelligence"**. Natural Medicine, 50.

20. Pratik Prabhanjan Brahma, Q.H. (2018) **Memoria estructurada basada en un modelo de aprendizaje profundo para detectar y además caracterizar entradas novedosas**, “Structured Memory based Deep Model to Detect as well as Characterize Novel Inputs”. IEEE,1-2

E-GRAFÍA

1. Wikipedia: The Free Encyclopedia. (s.f.). **Red Neural Artificial**, “Artificial Neural Network”. Extraído el 18 de septiembre de 2019
http://en.wikipedia.org/wiki/Artificial_neural_network
2. Baydin, A. G., Pearlmutter, B., Radul, A. A., & Siskind, J. (2018). **Diferenciación automática en aprendizaje de máquinas: una encuesta**, “Automatic differentiation in machine learning: a survey”. Journal of Machine Learning Research, 18, 1–43. Extraído el 19 de septiembre de 2019.
<http://jmlr.org/papers/v18/17-468.html>
3. Chilamkurthy, S. (2018). **Desarrollo y validación de algoritmos de aprendizaje profundo para la detección de hallazgos críticos en tomográficas craneales**, “Development and Validation of Deep Learning Algorithms for Detection of Critical Findings in Head CT Scans”. Obtenido de ResearchGate. Extraído el 19 de septiembre de 2019
https://www.researchgate.net/publication/323796532_Development_and_Validation_of_Deep_Learning_Algorithms_for_Detection_of_Critical_Findings_in_Head_CT_Scans
4. Wikipedia: The Free Encyclopedia. (s.f.). **Crowdsourcing**. Extraído el 18 de septiembre de 2019, de Wikipedia: The Free Encyclopedia:
<http://en.wikipedia.org/wiki/Crowdsourcing>
5. Crowther, R. A., DeRosier, D. J., Klug, A., & S, F. R. (s.f.). **La reconstrucción de una estructura tridimensional a partir de proyecciones y su aplicación al microscopio electrónico**, “The reconstruction of a three-dimensional structure from projections and its application to electron microscopy”.

- Proc. R. Soc. Lond. A, 317(1530), 319–340. Extraído el 18 de septiembre de 2019.
<http://rspa.royalsocietypublishing.org/content/317/1530/319>
6. Deng, L., & Yu, D. (2014). **Aprendizaje profundo, métodos y aplicaciones, “Deep Learning: Methods and Applications”**. Foundations and Trends in Signal Processing, 7(3–4), 1–199. Extraído el 18 de septiembre de 2019
<http://research.microsoft.com/pubs/209355/DeepLearning-NowPublishing-Vol7-SIG-039.pdf>
 7. Grossberg, S. (2013). **Redes recurrentes neurales, “Recurrent Neural Networks”**. Scholarpedia”, 8(2), 1888. Extraído el 19 de septiembre de 2019
http://scholarpedia.org/article/recurrent_neural_networks
 8. Hernández Cruz, J. (2019). **Interpreta una tomografía**. Obtenido de Sapiens Edicus. Extraído el 21 de marzo de 2019
<https://sapiensmedicus.org/interpreta-una-tac-craneal-en-8-sencillos-pasos/>
 9. Wikipedia: The Free Encyclopedia. **Hiper parámetro, “Hyperparameter”**. (s.f.). Extraído el 19 de septiembre de 2019
<http://en.wikipedia.org/wiki/Hyperparameter>
 10. MedlinePlus. (2019). **Accidente isquémico transitorio**. Extraído el 23 de abril de 2019
<https://medlineplus.gov/spanish/ency/article/000730.htm>
 11. National Institute of Biomedical Imaging and Bioengineering. (28 de 03 de 2019). **Tomografía Computarizada (TC)**. Obtenido de National Institute of Biomedical Imaging and Bioengineering. Extraído el 23 de abril de 2019
<https://www.nibib.nih.gov/espanol/temas-cientificos/tomograf%C3%ADa-computarizada-tc>
 12. Wikipedia, la enciclopedia libre, **Redes neuronales convolucionales**. (s.f.). Extraído el 19 de septiembre de 2019, de Wikipedia, la enciclopedia libre
http://es.wikipedia.org/wiki/Redes_neuronales_convolucionales
 13. Topol, E. (2019). **Un doctor explica como la inteligencia artificial puede mejorar el vínculo doctor paciente, “A doctor explains how artificial intelligence could improve the patient-doctor**

- bond**". (A. Chen, Entrevistador) Recuperado el 19 de marzo de 2019, Obtenido de The Verge:
<https://www.theverge.com/2019/3/12/18261718/eric-topol-deep-medicine-artificial-intelligence-algorithms-health-science-interview>
14. Traves, K. P., Studdiford, J. S., Pickle, S., & Tully, A. S. (2013). **Edema: diagnóstico y administración, "Edema: Diagnosis and Management"**. American Family Physician, 88(2), 102-110. Recuperado el 18 de 9 de 2019, de
<https://aafp.org/afp/2013/0715/p102.html>
15. MathWorks. **vgg19**. (s.f.). Obtenido de MathWorks. Recuperado el 1 de octubre de 2019
<https://www.mathworks.com/help/deeplearning/ref/vgg19.html;jsessionid=9fcb6301b3cc218e079fae21098a>
16. Wikimedia Commons. (29 de 03 de 2019). Archivo: **Tomografía cerebral humana computarizada, "Computed tomography of human brain"**. Obtenido de Wikimedia Commons. Recuperado el 1 de octubre de 2019
[https://commons.wikimedia.org/wiki/File:Computed_tomographt_of_human_brain_\(7\).png](https://commons.wikimedia.org/wiki/File:Computed_tomographt_of_human_brain_(7).png)

ANEXOS

Anexo I Resumen de imágenes y diagnósticos

El set de datos completo contiene información de 1,142 pacientes (anonimizados), Teniendo 771 pacientes con diagnósticos validos a evaluar, 266 pacientes sin enfermedades y 105 pacientes con imágenes sin ser posible clasificar.

Tabla No. XIII Distribución de datos de pacientes con diagnósticos validos

ENFERMEDAD	DIAGNÓSTICOS POSITIVOS	DIAGNOSTICOS NEGATIVOS
Hemorragia	229	542
Isquemia	81	690
Fractura	70	701
Masa	11	760
Edema	118	653

Fuente: Realización propia 2019.